



RavenStack

PROYECTO INTEGRADOR

Análisis y diagnóstico del abandono de clientes en una empresa SaaS y propuesta de un sistema de recomendación para la retención.

Bootcamp Unicorn Academy - Edición 13.0

Marta Quevedo Oltra

Fecha de entrega: 22-08-2026

ÍNDICE

Análisis y prevención del churn en RavenStack

1. RESUMEN EJECUTIVO	2
2. CONTEXTO Y PROBLEMÁTICA	3
2.1. La empresa	3
2.2. El problema de negocio	3
2.3. Objetivo del proyecto	3
2.4. Definición operativa de churn	4
3. PREGUNTAS DE NEGOCIO	5
3.1. Solución propuesta	5
4. METODOLOGÍA Y ARQUITECTURA TÉCNICA	5
4.1. Stack tecnológico	5
4.2. Flujo de datos	6
4.3. División de responsabilidades: Python y SQL	6
5. LOS DATOS	7
5.1. Fuente y obtención de los datos	7
5.2. Modelo de datos	7
5.3. Diccionario de tablas	8
6. FASES DEL PROYECTO	10
Fase 1 · Análisis exploratorio de datos	10
1.1. Objetivo y protocolo	10
1.2. Tabla accounts	11
1.3. Tabla subscriptions	12
1.4. Tabla feature_usage	12
1.5. Tabla churn_events	14
1.6. Tabla support_tickets	16
1.7. Registro de calidad de datos	17
1.8. Síntesis del EDA y orientación del análisis	17
Fase 2 · Modelado y creación de la base de datos en MySQL	21
2.1. DDL: qué es y por qué se separa de los datos	21
2.2. Decisiones de diseño	11
2.3. Las claves primarias y foráneas	22
2.4. Diagrama del modelo relacional	23
2.5. Ingesta de datos con Python	24
2.6. Protección de credenciales	24
2.7. Verificación final	24
Fase 3 · Auditoría de viabilidad del dataset original	25
3.1. Reformulación de la fase	25
3.2. Verificaciones previas	25
3.3. Definición operativa del churn	26
3.4. Primera vía: las características de la cuenta	27

3.5. Segunda vía: el comportamiento de la cuenta	27
3.6. Tercera vía: las causas declaradas	28
3.7. Cuarta vía: la estructura temporal	29
3.8. Veredicto de la auditoría	30
3.9. Limitación de la conclusión y transición	31
3.10. Nota metodológica: sobre el criterio para detenerse.....	31
Fase 4 · Banco de pruebas: validación de la sensibilidad del método	32
4.1. La pregunta que resuelve esta fase	32
4.2. Advertencia epistemológica	32
4.3. Estructura causal inyectada.....	33
4.4. Fidelidad al conjunto original	33
4.5. Modificaciones respecto del original	34
4.6. Verificación de coherencia temporal	34
4.7. Validación de sensibilidad.....	35
4.8. Errores de diseño detectados durante la validación.....	35
Fase 5 · Diagnóstico del churn.....	36
Bloque 0. Punto de partida	36
Bloque 1. Análisis del churn.....	37
Pregunta 1 — Cuantificación: ¿cuánto churn hay y cuánto cuesta?	37
Pregunta 2 — Caracterización: ¿logos pequeños o ingresos grandes?	41
Pregunta 3 — Causas: ¿por qué se van y cuánto cuesta cada motivo?	43
Pregunta 4 — Anticipación: ¿qué señal temprana anticipa la baja?	48
Fase 6 · Sistema de alerta temprana y recomendador de funcionalidades.....	53
6.1. Las señales.....	54
4.2. La puntuación.....	55
4.3. La matriz de priorización	55
4.4. La validación	56
4.5. El recomendador de funcionalidades	57
Fase 7 · Visualización en Power BI.....	58
7.1. Objeto de la fase	58
7.2. Origen de los datos y modelo	59
7.3. Portada y advertencia sobre el origen de los datos	59
7.4. Página 1 · Situación del negocio.....	60
7.5. Página 2 · Diagnóstico del abandono.....	61
7.6. Página 3 · Cartera viva en riesgo	62
7.7. Página 4 · Plan de acción.....	63
7.8. Medidas DAX.....	63
7.9. Modelo de datos.....	65
7. LIMITACIONES DEL TRABAJO	66
8. CONCLUSIONES	67
9. BIBLIOGRAFÍA.....	69

1. RESUMEN EJECUTIVO

Este proyecto se planteó como el **diagnóstico del abandono de clientes de RavenStack, una empresa SaaS de suscripción**, con el objetivo de identificar la señal que anticipa la cancelación y construir sobre ella un sistema de retención.

El análisis del conjunto de datos original reveló que ninguna variable discriminaba entre quien se marcha y quien permanece, y la investigación de ese resultado condujo a un hallazgo determinante: el 83,8 % de las cuentas dadas de baja registraba uso del producto con posterioridad a su cancelación, lo que invalida cualquier métrica de anticipación. La fase se cerró como auditoría de viabilidad del dato, con el veredicto de que no existe señal utilizable.

Para descartar que la ausencia de señal fuese una limitación del método y no del dato, **se construyó un conjunto sintético gemelo con verdad conocida sobre el que se ejecutó el mismo procedimiento sin modificarlo**: el método la detectó, confirmando que el resultado negativo era una propiedad del conjunto original.

El diagnóstico posterior invirtió la hipótesis de partida. Ninguna característica del cliente (plan, sector, tamaño o facturación) explica el abandono; lo explica la experiencia. **Las cuentas que cancelan usan el producto menos de la mitad que las activas, acumulan casi el doble de errores técnicos y reciben peor atención de soporte, y ese deterioro es gradual: la desconexión total es igualmente infrecuente en ambos grupos, de modo que esperar al silencio para intervenir supone llegar tarde**. El riesgo es uniforme en toda la cartera, pero el daño no: el 30 % de cuentas de mayor facturación concentra el 64 % de los ingresos, y once bajas del decil superior cuestan casi cuatro veces más que cuarenta y dos del inferior.

Sobre esas conclusiones se construyó un sistema de alerta temprana que combina seis señales observables, las cruza con el valor expuesto de cada cuenta y devuelve trece cuentas para atención directa sobre una cartera de 381. Validado retrospectivamente, identifica cuentas que abandonan cinco veces más que las de riesgo bajo.

La recomendación operativa es doble: priorizar la retención por valor expuesto y no por probabilidad de fuga, e intervenir sobre los tiempos de resolución del soporte en el tercio superior de la cartera, que es donde la pérdida sería mayor.

2. CONTEXTO Y PROBLEMÁTICA

2.1. La empresa

RavenStack es una empresa SaaS (Software as a Service) que comercializa su producto mediante suscripciones de pago. El análisis del modelo de negocio, realizado durante la fase exploratoria, permite caracterizarlo del siguiente modo:

- **Tres planes de suscripción de pago:** Basic, Pro y Enterprise.
- **Período de prueba (trial):** previo a la conversión a plan de pago.
- **Sin tier gratuito permanente:** no existe una modalidad *freemium*. Un cliente que cancela su suscripción abandona el servicio por completo.
- **Las suscripciones se dimensionan por seats** (licencias de usuario), lo que determina el tamaño y el valor de cada cuenta.

Importancia de esta caracterización. La ausencia de un plan gratuito no es un detalle descriptivo, sino que determina la definición misma de churn. En modelos *freemium* (Spotify sería el ejemplo canónico), un cliente que cancela su suscripción de pago no abandona el servicio: se degrada a la versión gratuita y sigue siendo usuario. **En RavenStack no existe esa posibilidad, por lo que la cancelación equivale al abandono (churn).** Sin esta verificación previa, la definición operativa de churn, habría quedado sin fundamento.

2.2. El problema de negocio

Como toda empresa de suscripción recurrente, RavenStack depende de la retención de sus clientes para sostener sus ingresos. La **pérdida de clientes (churn) impacta directamente en los ingresos recurrentes** y obliga a una adquisición constante de nuevos clientes, notablemente más costosa que retener a los existentes.

2.3. Objetivo del proyecto:

El objetivo de este proyecto es **diagnosticar el churn** de una empresa SaaS y construir sobre ese diagnóstico un mecanismo de retención accionable: **cuantificar el abandono, caracterizarlo, entender sus causas e identificar la señal temprana que lo anticipa.**

Sin embargo, el desarrollo del proyecto obligó a desdoblar ese objetivo. La auditoría del dataset de origen (Fase 3) concluyó que los datos originales de RavenStack **no admiten un diagnóstico claro de churn.**

Ante ese resultado caben dos lecturas: que no exista señal, o que el método empleado sea incapaz de detectarla.

El objetivo queda por tanto formulado en dos niveles:

- Nivel metodológico: (fase 4) **demostrar que el procedimiento analítico empleado posee sensibilidad suficiente para detectar señal cuando la hay**, de modo que un resultado negativo pueda interpretarse como propiedad del dato y no como limitación del análisis.
- Nivel de negocio: (fase 5) **diagnosticar el churn y proponer un sistema de alerta temprana con priorización de funcionalidades a impulsar** para cada cuenta en riesgo.

2.4. Definición operativa de churn

Una decisión metodológica temprana y relevante fue **cómo definir el churn**, dado que el dataset permite medirlo a distintos niveles.

Decisión adoptada para tal definición y medición es: **toda cancelación de cuenta (logo churn) es contabilizado como churn, siempre que el último evento sea baja sin reactivación.**

Justificación: una cuenta puede tener múltiples suscripciones a lo largo del tiempo (cambios de plan, *upgrades*, *downgrades*). Contabilizar cada suscripción finalizada como un evento de churn sobredimensionaría el problema, ya que un cliente que cambia de plan sigue siendo cliente. **El abandono real del servicio se produce cuando la cuenta cancela sin continuidad.**

Métrica complementaria: Revenue churn . Las cuentas de RavenStack son muy heterogéneas en tamaño (de 1 a 163 seats). Perder diez cuentas pequeñas no equivale a perder diez cuentas grandes, pero el problema de tener solo en cuenta el *logo churn* es que éste las trataría como idénticas. Para la empresa no supone lo mismo perder esas diez cuentas grandes que diez muy pequeñas.


Por lo tanto, se reportarán ambas métricas de forma conjunta:

Métrica	Qué mide	Unidad	Pregunta que responde
Logo churn	Cientes perdidos	Cuentas	¿Cuántos clientes se van?
Revenue churn	Ingresos perdidos	MRR / ARR	¿Cuánto nos duele?

La lectura cruzada de ambas métricas constituye un hallazgo en sí misma: **si el revenue churn supera al logo churn, significa que se están perdiendo los clientes de mayor valor, una alarma cualitativamente distinta.**

3. PREGUNTAS DE NEGOCIO

¿Cómo abordar el churn de clientes?



3.1. Solución propuesta


A partir de la **pregunta 4**, se propone un **sistema de alerta temprana y recomendador de funcionalidades** que, una vez detectada una cuenta en riesgo, le sugiera qué funcionalidades impulsar basándose en el comportamiento de cuentas similares que sí se han retenido.

4. METODOLOGÍA Y ARQUITECTURA TÉCNICA

4.1. Stack tecnológico

Herramienta	Uso en el proyecto	Justificación
Python (Notebook)	Extracción vía API, análisis exploratorio (EDA) e ingesta de datos.	Flexibilidad para exploración y cálculo matricial.
MySQL	Modelado relacional, limpieza, consultas analíticas y creación de vistas.	Núcleo del análisis: los datos son relacionales y las transformaciones son operaciones de conjunto.
Power BI	Modelado en estrella, medidas DAX, dashboard final.	Visualización y comunicación de resultados.

4.2. Flujo de datos



4.3. División de responsabilidades: Python vs. SQL

Una decisión de arquitectura relevante fue **dónde ejecutar la limpieza de datos**.

Criterio adoptado:

🔧 **Python (EDA):** función **diagnóstica**. Explorar, detectar anomalías, entender la estructura. No se corrigen los datos aquí; se *identifican* los problemas.

🔧 **MySQL:** función **correctiva**. Es donde se aplican las decisiones de limpieza (tipos de dato, tratamiento de nulos, claves, integridad referencial).

Justificación:

Los datos son relacionales (cinco tablas interconectadas) y las transformaciones necesarias son fundamentalmente operaciones de conjunto (joins, agregaciones, deduplicación). SQL es la herramienta natural para ello. La única excepción es el parseo de fechas en Python, necesario para poder explorar las variables temporales durante el diagnóstico.

5. LOS DATOS

5.1. Fuente y obtención de los datos.

Se emplea el [dataset SaaS Subscription & Churn Analytics \(Kaggle\)](#), un conjunto de datos simulados de comportamiento de usuarios en una empresa SaaS.


La obtención se realiza mediante la API de Kaggle (instalando la librería **kagglehub** en **Python**). Esta decisión responde a un criterio de replicabilidad: la ingesta programática garantiza que cualquier persona que ejecute el notebook obtenga exactamente los mismos datos desde la fuente original, sin dependencias de archivos locales ni rutas codificadas manualmente.

5.2. Modelo de datos.

El dataset se compone de **cinco tablas relacionadas**:

Tabla	Registros	Naturaleza	Clave
accounts	500	Dimensión	<i>account_id</i> (PK)
subscriptions	5.000	Dimensión (híbrida)	<i>subscription_id</i> (PK) <i>account_id</i> (FK)
feature_usage	25.000	Hechos	<i>subscription_id</i> (FK)
churn_events	600	Hechos	<i>account_id</i> (FK)
support_tickets	2.000	Hechos	<i>account_id</i> (FK)

Estructura relacional:



Observación de modelado: asimetría en las claves de unión.

Las tablas **churn_events** y **support_tickets** se enlazan directamente con *account_id*, mientras que **feature_usage** lo hace a través de *subscription_id*. Para relacionar un evento de uso con su cuenta correspondiente es necesario, por tanto, un salto de dos tablas:

feature_usage → subscriptions → accounts.

Esta particularidad condicionará tanto las consultas analíticas como la construcción de la matriz cuenta-feature del sistema de recomendación.

5.3. Diccionario de tablas.

Los dos conjuntos de datos empleados en el proyecto comparten esquema y se diferencian únicamente en volumen de filas de dos tablas:

Tabla	RavenStack (original)	Gemelo sintético
accounts	500	500
subscriptions	5.000	1.164
feature_usage	25.000	25.000
churn_events	600	238
support_tickets	2.000	2.000

Los nombres, el orden y los tipos de todas las columnas son idénticos, así como las cinco relaciones de clave foránea. **El fichero ddl ravenstack gemelo.sql se ejecuta sin modificación alguna sobre ambos conjuntos.**

accounts - 500 filas: una fila por cuenta/empresa cliente.

Column	Type	Description
<i>account_id</i>	ID	Identificador único de la cuenta (clave primaria)
<i>account_name</i>	string	Nombre de la empresa (anonimizado)
<i>industry</i>	categorical	Sector de la cuenta (EdTech, FinTech, DevTools...)
<i>country</i>	string	País de la cuenta (código ISO de dos letras)
<i>signup_date</i>	date	Fecha de alta / registro de la cuenta
<i>referral_source</i>	categorical	Canal de adquisición (partner, organic, other...)
<i>plan_tier</i>	categorical	Plan contratado a nivel de cuenta (Basic, Pro, Enterprise)
<i>seats</i>	integer	Nº de licencias/asientos a nivel de cuenta
<i>is_trial</i>	boolean	Si la cuenta está en periodo de prueba (True/False)
<i>churn_flag</i>	boolean	Marca booleana de baja a nivel de cuenta (contradice a churn_events)

subscriptions - 5.000 filas: una fila por suscripción; varias por cuenta.

Column	Type	Description
<i>subscription_id</i>	ID	Identificador único de la suscripción (clave primaria)
<i>account_id</i>	ID (FK)	Cuenta a la que pertenece (clave foránea → accounts)
<i>start_date</i>	date	Fecha de inicio de la suscripción
<i>end_date</i>	date	Fecha de fin; NULL = suscripción activa
<i>plan_tier</i>	categorical	Plan de esta suscripción concreta
<i>seats</i>	integer	Asientos de esta suscripción
<i>mrr_amount</i>	currency	M Ingreso recurrente mensual de la suscripción (USD)
<i>arr_amount</i>	currency	Ingreso recurrente anual ($\approx mrr \times 12$)
<i>is_trial</i>	boolean	Si la suscripción está en período de prueba
<i>upgrade_flag</i>	boolean	Si esta suscripción reflejó una subida de plan
<i>downgrade_flag</i>	boolean	Si reflejó una bajada de plan
<i>churn_flag</i>	boolean	Si esta suscripción terminó/canceló
<i>billing_frequency</i>	categorical	Periodicidad de facturación (monthly, annual)
<i>auto_renew_flag</i>	boolean	Si tiene renovación automática activada (80% true)

feature_usage - 25.000 filas: una fila por evento de uso de una feature

Column	Type	Description
<i>usage_id</i>	ID	Identificador del evento de uso
<i>subscription_id</i>	ID (FK)	Suscripción que generó el uso (clave foránea → subscriptions)
<i>usage_date</i>	date	Fecha del evento de uso
<i>feature_name</i>	categorical	Funcionalidad usada (40 funcionalidades)
<i>usage_count</i>	integer	Nº de veces que se usó la feature en ese registro
<i>usage_duration_secs</i>	integer	Duración de uso en segundos
<i>error_count</i>	integer	Nº de errores registrados durante el uso
<i>is_beta_feature</i>	boolean	Si la feature está en beta (10% beta)


churn_events - 600 filas: una fila por evento de baja.

Column	Type	Description
<i>churn_event_id</i>	ID	Identificador único del evento de baja
<i>account_id</i>	ID (FK)	Cuenta que se dio de baja (clave foránea → accounts)
<i>churn_date</i>	date	Fecha en que se produjo la baja
<i>reason_code</i>	categorical	Motivo categorizado (pricing, support, budget...)
<i>refund_amount_usd</i>	currency	Importe reembolsado al dar de baja (USD (25% have credit/refund))
<i>preceding_upgrade_flag</i>	boolean	Si hubo un upgrade justo antes de la baja
<i>preceding_downgrade_flag</i>	boolean	Si hubo un downgrade justo antes
<i>is_reactivation</i>	boolean	Probablemente marca si el evento corresponde a una reactivación (10% were previously churned)
<i>feedback_text</i>	string	Comentario libre del cliente al darse de baja (puede estar vacío)

support_tickets - 2.000 filas: una fila por ticket de soporte

Column	Type	Description
<i>ticket_id</i>	ID	Identificador único del ticket
<i>account_id</i>	ID (FK)	Cuenta que abrió el ticket (clave foránea → accounts)
<i>submitted_at</i>	datetime	Fecha de apertura del ticket
<i>closed_at</i>	datetime	Fecha/hora de cierre (timestamp)
<i>resolution_time_hours</i>	float	Tiempo total hasta la resolución (horas)
<i>priority</i>	categorical	Prioridad asignada (low, high, urgent...)
<i>first_response_time_minutes</i>	integer	Tiempo hasta la primera respuesta (minutos)
<i>satisfaction_score</i>	integer	Puntuación de satisfacción 1-5 (null = no response)
<i>escalation_flag</i>	boolean	Si el ticket fue escalado

6. FASES DEL PROYECTO.



Fase 1 · Análisis Exploratorio de Datos (EDA)

1.1. Objetivo y protocolo

El análisis exploratorio en Python cumple una función estrictamente diagnóstica: conocer la calidad, la estructura y la forma de los datos con el fin de determinar qué análisis podrán sostenerse posteriormente y qué operaciones de limpieza serán necesarias en la fase de MySQL.

Protocolo aplicado sistemáticamente a cada una de las cinco tablas:

.info() — tipos de dato y presencia de nulos.

.isnull().sum() — cuantificación de nulos por columna.

.duplicated() — verificación de unicidad en las columnas clave (en caso necesario).

.describe() — distribución de las variables numéricas para detección de outliers, sesgos y rangos imposibles.

.describe(include = 'str') — cardinalidad y valores dominantes en las variables categóricas.

pd.to_datetime() — parseo de fechas, para habilitar el análisis temporal.

Nota metodológica sobre el parseo de fechas:

Se optó por el comportamiento por defecto de **pd.to_datetime()** porque lanza un error ante cualquier valor que no se pueda convertir. El parámetro `errors='coerce'`, convierte silenciosamente a nulo los valores problemáticos. En una fase de diagnóstico sobre un dataset desconocido, es preferible que los datos corruptos se manifiesten explícitamente antes de queden enmascarados como nulos indistinguibles de los nulos legítimos.

1.2. Tabla accounts (500 registros)

Calidad de los datos:

- **Nulos:** ninguno.
- **Duplicados:** *account_id* presenta 500 valores únicos sobre 500 filas. La clave primaria es válida y no existe duplicación.
- **Tipos de dato:** *signup_date* se carga como texto (str) y requiere parseo.

Composición de la base de clientes

- **Cardinalidad:** 5 industrias, 7 países y 3 planes de suscripción (Basic, Pro, Enterprise).
- **Concentración geográfica:** Estados Unidos concentra 291 de las 500 cuentas (58 %).
- **Distribución de seats:** media 20,56 / mediana 15/ máximo 163.

Hallazgo: asimetría en el tamaño de las cuentas: La media de *seats* (20,6) es superior a la mediana (15), lo que indica que, estadísticamente hablando, hay una distribución sesgada a la derecha, porque existe un gran número de cuentas pequeñas y un número reducido de cuentas muy grandes pero que elevan el promedio.

Implicación de negocio: La "cuenta media" de RavenStack no existe como cliente típico; es un artefacto estadístico. La heterogeneidad de tamaño de las cuentas obliga a ponderar el churn por el valor de cada cuenta, y no simplemente a contar cuentas perdidas. Este hallazgo es el que motiva la incorporación del revenue churn como métrica complementaria al logo churn (véase el apartado 2.3).

1.3. Tabla subscriptions (5.000 registros)

Calidad de los datos

- **Nulos:** 4.514 en *end_date*. No constituyen datos faltantes, sino nulos con significado semántico: una suscripción sin fecha de fin es una suscripción activa. Los 486 registros restantes corresponden a suscripciones finalizadas.
- **Duplicados:** *subscription_id* presenta 5.000 valores únicos; la clave primaria es válida. *account_id* registra 500 valores únicos sobre 5.000 filas, lo cual es correcto por diseño de negocio: una cuenta puede mantener múltiples suscripciones a lo largo del tiempo. La cuenta A-d4ac0e acumula 19.
- **Validación de coherencia:** se verifica la relación $arr_amount \approx mrr_amount \times 12$ (media MRR: 2.267,75; media ARR: 27.212,99). La relación se cumple.
- **Valor sospechoso:** *mrr_amount* presenta un mínimo de 0. Hipótesis: corresponde a suscripciones en período de prueba, que aún no generan ingresos. Pendiente de verificación contra *is_trial*.
- **Rango temporal:** altas registradas entre 2023-01-09 y 2024-12-31.

Precisión metodológica: (suscripción finalizada $\neq$ cuenta perdida). Las 486 suscripciones con fecha de fin no equivalen a 486 cuentas perdidas. Una suscripción puede finalizar por un simple cambio de plan (se cierra la Basic para abrir una Pro), lo que no constituye churn bajo la definición adoptada. El logo churn real debe determinarse cruzando esta información con los eventos de cancelación registrados.

1.4. Tabla feature_usage (25.000 registros)

Tabla de hechos. Cada fila registra el uso de una funcionalidad concreta por parte de una suscripción en una fecha determinada. Es, en términos analíticos, el equivalente a la tabla de ventas de un comercio electrónico.

Estructura y distribuciones

- **Catálogo de funcionalidades:** 40 features distintas. El uso está muy repartido, sin dominancia clara de ninguna funcionalidad.
- **Distribuciones:**
 - *usage_count* (media 10, desviación estándar 3,14) presenta una dispersión baja.
 - *usage_duration_secs* (media 3.042; desviación 2.056) presenta una dispersión muy elevada: los tiempos de uso varían enormemente entre eventos.
 - *error_count* (media 0,56; máximo 8) es cero en la mayoría de los registros.

- **Valores sospechosos:** *usage_count* y *usage_duration_secs* presentan mínimo 0. Un evento de uso con contador y duración nulos requiere interpretación.

Hallazgo: anomalía en *usage_id* . La columna presenta 24.979 valores únicos sobre 25.000 filas, **lo que revela 21 identificadores duplicados** (42 filas afectadas).

Al inspeccionar las filas implicadas se comprueba que no se trata de registros duplicados, sino de eventos genuinamente distintos (diferente *subscription_id*, diferente *feature_name*, diferente *usage_date*) que comparten identificador. Se trata, por tanto, de un fallo en la generación del identificador en el sistema de origen, no de una duplicación de datos.

(El tratamiento de esta anomalía se detalla en el apartado 7.1, por su interés metodológico.)

Hallazgo: suscripciones sin actividad registrada: Aparecen 4.967 *subscription_id* distintos en la tabla, frente a las 5.000 suscripciones existentes. Existen, por tanto, 33 suscripciones que no registran ningún uso del producto.

Implicación de negocio: Estas 33 suscripciones constituyen una señal de riesgo de máxima intensidad. Un cliente que contrata el producto y no lo utiliza en absoluto es el candidato más evidente al abandono. Este segmento se incorpora al análisis de la pregunta 4 (identificación de cuentas en riesgo) como grupo de riesgo extremo.

Supuesto interpretativo sobre *usage_count*: El glosario del dataset define *usage_count* como “event frequency”, una formulación ambigua. Se asume, por coherencia con la estructura de la tabla, que la columna representa el número de invocaciones de una funcionalidad concreta en la fecha registrada (esto es, la intensidad de uso dentro de un evento) y no la frecuencia de uso de la cuenta.

Consecuencia analítica: la frecuencia de uso de una cuenta (la dimensión F del modelo RFM) no está disponible como columna y deberá construirse mediante agregación, contando los eventos o días distintos de actividad por cuenta. La distinción es crítica: leer *usage_count* como frecuencia de cuenta produciría métricas erróneas.

1.5. Tabla churn_events (600 registros)

Estructura

- **600 eventos sobre 352 cuentas únicas.** Una misma cuenta puede haber cancelado, reactivado y vuelto a cancelar, generando varios eventos para una misma cuenta. La columna *is_reactivation* confirma esta lectura: 61 de los 600 eventos corresponden a reactivaciones. Es decir, una misma cuenta aparece varias veces (baja, reactivación, nueva baja..) y algunas de esas filas no son un abandono.
- **Implicación crítica:** 600 eventos de churn no equivalen a 600 clientes perdidos. El logo churn debe calcularse sobre cuentas únicas (nunca sobre filas de eventos) y definir una regla explícita para obtener el último evento de churn (ordenado por *churn_date*) y tratar *is_reactivation* como un evento que cancela una baja previa.
- **Nulos:** 148 en *feedback_text* (452 valores informados). Se interpretan como cancelaciones sin comentario declarado.

Causas declaradas:

- *reason_code*: **6 categorías parametrizadas:** pricing, support, budget, unknown, features, competitor. La más frecuente es features (114 eventos), es decir, la ausencia de funcionalidades demandadas.
- *feedback_text*: **3 valores parametrizados:** 'switched to competitor', 'missing features', 'too expensive'. No se trata de texto libre. Solapa parcialmente con *reason_code* (competitor, features, pricing), pero no cubre las categorías support, budget ni unknown.
- *refund_amount_usd*: los percentiles 25, 50 y 75 son todos 0. **Más del 75 % de las cancelaciones no generan reembolso alguno;** la media de 14,42 está inflada por una minoría de reembolsos elevados (máximo 392,92). Se trata, nuevamente, de una distribución fuertemente sesgada.

Hallazgo: los cambios de plan no anticipan el abandono. El dataset registra si se produjo un upgrade o un downgrade en los 90 días previos a cada cancelación. Los resultados contradicen la hipótesis de partida:

- **Solo 53 de 600 eventos (8,8 %)** estuvieron precedidos por un downgrade.
- **En cambio, 123 eventos (20,5 %)** estuvieron precedidos por un upgrade: más del doble.

Implicación para el análisis: La hipótesis inicial que me había formulado sobre que un cliente degrada su plan antes de abandonar, queda severamente debilitada: la inmensa mayoría de las cancelaciones se produce sin esa señal de aviso.

El downgrade no es, por tanto, un predictor útil del churn. Este resultado reorienta la búsqueda de señales tempranas hacia el comportamiento de uso del producto (*feature_usage*), lo que a su vez refuerza la pertinencia del sistema de recomendación propuesto: actúa precisamente sobre la señal que sí resulta informativa.

Cuestión abierta para la fase de diagnóstico: *¿Qué explica que un cliente mejore su plan de suscripción y cancele poco después?*

El fenómeno merece investigación específica, pues las explicaciones que pueden parecer plausibles: expectativas incumplidas tras la ampliación, un upgrade forzado por necesidades que el producto no llegó a cubrir, o un cambio organizativo en el cliente, conducirían a acciones muy distintas.

Hallazgo crítico: inconsistencia entre fuentes de churn. El dataset ofrece dos fuentes distintas para determinar qué cuentas han abandonado, y ambas se contradicen:

Fuente	Cuentas de churn	% sobre 500
churn_events	352	70,4%
accounts.churn_flag	110	22,0%

Se ejecuta una verificación de integridad mediante el cruce de ambos conjuntos, cuyo resultado confirma la incoherencia:

Situación	Cuentas
Con evento registrado de churn, pero con accounts.churn_flag = False	277
Sin evento registrado de churn, pero con accounts.churn_flag = True	35
Coincidentes en ambas fuentes	75

Las 277 cuentas del primer caso constituyen una contradicción lógica: el glosario define *churn_flag* como "churned at any point" (canceló en algún momento), de modo que una cuenta con evento registrado debería tener necesariamente la flag activada.

Las reactivaciones no explican la discrepancia, pues solo se registran 61 en toda la tabla, muy lejos de las 277 necesarias. Las 35 cuentas del segundo caso representan la contradicción inversa: la flag afirma un abandono sin que exista ningún evento registrado que lo respalde.

Conclusión: no existe interpretación de negocio que reconcilie ambas fuentes. **El dataset es internamente inconsistente, circunstancia plausible tratándose de datos generados sintéticamente.** Se descarta, por tanto, forzar una narrativa explicativa sobre lo que constituye un problema de calidad de datos.

Decisión adoptada: considerar la tabla de churn_events como fuente de verdad, pero hay que investigar los 35 casos huérfanos antes de descartarlos porque pueden ser bajas reales cuyo evento se perdió.

Justificación. Un evento es el registro de un hecho ocurrido, dotado de fecha y motivo; en cambio una flag es un campo derivado, un resumen calculado susceptible de error. A este argumento de fiabilidad se añade uno de suficiencia analítica: `churn_events` es la única fuente que permite responder a las preguntas 3 y 4 del proyecto (por qué se van y cuándo se van). La flag únicamente permitiría contar.

Consecuencias operativas de la decisión:

- **El logo churn se establece en las cuentas únicas de la tabla `churn_events` dónde su último movimiento registrado es una baja sin reactivación.** En la tabla hay 352 cuentas únicas registradas con eventos de churn, pero hay que tener en cuenta las reactivaciones y cómo estas coinciden con el último evento registrado de la cuenta.
- **La columna `churn_flag` queda, en principio, descartada como métrica de churn en `accounts` y `subscriptions`.** De todos modos, se conserva en el modelo para investigar sobre las 35 cuentas sin registro de eventos para no subestimar el churn de la empresa.

1.6. Tabla `support_tickets` (2.000 registros)

Calidad de los datos

- **Nulos: 825 en `satisfaction_score`** (1.175 valores informados sobre 2.000). El glosario aclara que un valor nulo significa que el cliente no respondió a la encuesta. Se trata de un nulo legítimo, pero implica que el 41% de los tickets carece de puntuación: cualquier conclusión sobre satisfacción se sustentará en menos de la mitad de los registros.
- **Duplicados:** `ticket_id` presenta 2.000 valores únicos. Clave primaria válida sin duplicados.

Rendimiento del soporte

- `resolution_time_hours`: **de 1 a 72 horas** (máximo 3 días); media de 35,9 horas.
- `first_response_time_minutes`: **máximo 180 minutos** (3 horas); media de 88,5 minutos.
- `escalation_flag`: 95 tickets escalados (4,75 %).
- `satisfaction_score`: media de 3,98 sobre 5; mínimo registrado 3.

Anomalía encontrada: ausencia de puntuaciones más bajas

Pese a que la escala de satisfacción es de 1 a 5, el valor mínimo registrado en toda la tabla es 3. No existe ni una sola puntuación de 1 o 2.

Resulta inverosímil que ningún cliente de una base de 500 cuentas haya manifestado nunca una insatisfacción severa. Este hecho anómalo se atribuye al carácter sintético del dataset, por tener valores que parecen haberse generado dentro de un rango restringido.

Consecuencia: la variable *satisfaction_score* puede que codifique como nulo las puntuaciones más bajas. O que la variable no tenga poder discriminante y debe emplearse con cautela como predictor de abandono.

Como abordarlo: primero, comprobar si la nulidad se correlaciona con *escalation_flag*, *priority* o *resolution_time_hours* (si los nulos se concentran en tickets escalados o lentos, el nulo puede que sean la insatisfacción).

Hallazgo: el soporte no discrimina entre cuentas. La tabla registra 492 cuentas únicas sobre las 500 existentes: el 98,4 % de los clientes ha abierto algún ticket de soporte.

Implicación analítica. Una señal presente en la práctica totalidad de la población carece de poder discriminante: el mero hecho de haber abierto tickets no distingue a las cuentas que abandonan de las que permanecen.

La señal, **de existir**, no reside en la presencia de tickets, sino en su intensidad relativa: el número de tickets por cuenta, la presencia de escalaciones, puntuaciones bajas, etc, magnitudes que solo podrán evaluarse mediante el cruce con los eventos de churn en la fase de análisis.

A ello se añade que las métricas agregadas del soporte son razonablemente buenas (resolución en menos de tres días, primera respuesta en menos de tres horas, escalado inferior al 5 %), **lo que debilita la hipótesis de que el soporte constituya una causa principal del abandono.**

No obstante, la hipótesis no se descarta: la categoría support figura entre las causas declaradas en reason code, por lo que se mantiene como línea de investigación secundaria, esta vez atendiendo a la intensidad y no solo a su existencia.

1.7 Registro de calidad de datos.

Se mantiene en Excel un registro sistemático de las anomalías detectadas durante la fase exploratoria, de la decisión adoptada sobre cada una y de su justificación. Este registro constituye la trazabilidad de las transformaciones aplicadas al conjunto de datos y permite auditar cualquier resultado del análisis hasta su origen.

Tabla	Columna	Anomalía	Nº casos	Decisión y justificación
TODAS LAS TABLAS	<i>fechas</i>	Las columnas que contienen fechas vienen tipo texto	Todas las tablas	Parsear a datetime (Python) y tipar como DATE (SQL). Necesario para el análisis temporal.
ACCOUNTS	<i>seats</i>	Distribución sesgada (media 20,6> mediana 15; máx.163)	--	No es un error pero indica heterogeneidad real de las cuentas. Es el motivo por el cual se adopta revenue churn como métrica complementaria.
SUBSCRIPTIONS	<i>end_date</i>	4514 nulos	4514	Se trata de nulos legítimos que no tienen fecha de cancelación = suscripción activa
	<i>mrr_amount</i>	Valor mínimo = 0	Verificado	Verificar si todos los MRR = 0 corresponden a <i>is_trial</i> = 1. Si un cliente de pago registrara MRR nulo, existiría una inconsistencia. En todo caso, no deben mezclarse trials y clientes de pago al calcular ingresos medios.
	<i>mrr_amount</i>	Valor mínimo = 0	Verificado	Queda verificado con una query al inicio de la Fase 3, en el análisis en MySQL que los 0 en <i>mrr_amount</i> corresponden a clientes en período de prueba (778 suscripciones). Al calcular MRR/ARR medios reales, siempre habrá que filtrar <i>is_trial</i> = 0, de lo contrario, se mezclaría el valor de ingresos medios con los clientes de pago y hundiría la media.
FEATURE_USAGE	<i>usage_id</i>	21 Ids duplicados de eventos distintos	42	Conservar. Creación de una PK substituta en SQL. * (leer nota metodológica debajo de la tabla)
	<i>subscription_id</i>	33 suscripciones sin registro de uso	33	Investigar: ¿significa esta inactividad que es riesgo extremo de churn?
	<i>usage_count / usage_duration_secs</i>	Valor mínimo = 0	Verificado	Interpretar el significado de un evento de uso con contador y duración nulos
	<i>usage_count / usage_duration_secs</i>	Valor mínimo = 0	Verificado	RESULTADO: 2 registros de 25.000 con <i>usage_count</i> = 0. Volumen despreciable. No se toma ninguna acción ya que no afecta a las agregaciones de intensidad/frecuencia.
	<i>usage_count</i>	Definición ambigua en el glosario ("event frequency")	--	Se asume que representa las invocaciones de la feature en la fecha registrada. La frecuencia de uso por cuenta (F del RFM) deberá construirse por agregación.
ACCOUNTS/ CHURN_EVENTS	<i>churn_flag</i>	Inconsistencia entre fuentes: 277 cuentas con evento pero flag = False; 35 con flag = True sin evento.	277 + 35 = 312	Fuente de verdad: <i>churn_events</i> . La flag se descarta para el cálculo de métricas. Los eventos son hechos registrados con fecha y motivo; la flag es un campo derivado. Se asume la subestimación de hasta 35 cuentas.solo <i>churn_events</i> permite responder cuándo y por qué se produce el abandono.
CHURN_EVENTS	<i>feedback_text</i>	148 nulos	148	Conservar. Se interpretan como cancelaciones sin comentario declarado.

SUPPORT_TICKETS	satisfaction_score	825 nulos (41 %)	825	Nulo legítimo (cliente sin respuesta). Limita el análisis de satisfacción a menos de la mitad de los tickets.
		Mínimo registrado = 3, pese a escala 1-5	—	Anomalía atribuible al carácter sintético del dataset. La variable pierde capacidad discriminante; emplear con cautela.
	account_id	492 de 500 cuentas (98,4 %) han abierto tickets	—	La presencia de tickets no discrimina. Analizar intensidad (nº de tickets, escalaciones) en lugar de presencia.

***Nota metodológica: tratamiento de identificadores no fiables.**

La anomalía detectada en *usage_id* plantea un problema de modelado relacional cuyo tratamiento merece detallarse, por ser ilustrativo del criterio aplicado a lo largo de todo el proyecto.

El problema: 21 identificadores se repiten en registros que corresponden a eventos genuinamente distintos. Al declarar *usage_id* como PRIMARY KEY en MySQL, el motor rechazaría las filas duplicadas, provocando la pérdida de 21 eventos válidos.

Opciones evaluadas:

1. **Eliminar las filas afectadas.** Descartada. Los registros corresponden a eventos reales y su eliminación supondría una pérdida de información válida.
2. **Reasignar los identificadores manualmente.** Descartada. Implicaría inventar datos sin criterio objetivo y exigiría, además, verificar la ausencia de colisión con los identificadores existentes.
3. **Generar una clave sustituta (surrogate key).** Adoptada. Se crea una columna id INT AUTO_INCREMENT PRIMARY KEY generada por el propio motor en la carga. La columna *usage_id* original se conserva como atributo informativo, pero deja de ser clave primaria.

```
CREATE TABLE feature_usage (
  id INT AUTO_INCREMENT PRIMARY KEY, -- clave sustituta generada por el sistema
  usage_id VARCHAR(20),             -- identificador de origen, sin función de clave
  subscription_id VARCHAR(20),
  ... );
```

En un entorno productivo, la corrección debería aplicarse en el sistema de origen, no aguas abajo. Un pipeline que parchea identificadores defectuosos en cada carga constituye una solución frágil: el problema se repetiría indefinidamente. Lo correcto sería escalar la incidencia al equipo responsable de la generación de los datos. Al tratarse de un dataset estático y cerrado, esta vía no está disponible en el presente proyecto, y se deja constancia de ello como parte de la reflexión metodológica.

1.8. Síntesis del EDA y orientación del análisis.

El análisis exploratorio permite cerrar la fase diagnóstica con cinco conclusiones que orientan el trabajo posterior:

1. La base de clientes es muy heterogénea y requiere aplicar métricas ponderadas.

La distribución de seats está fuertemente sesgada. Contar cuentas perdidas sin ponderar su valor produciría un diagnóstico engañoso. De ahí la decisión de reportar conjuntamente logo churn y revenue churn.

2. El dataset presenta una inconsistencia de primer orden que ha exigido una decisión metodológica. Las dos fuentes disponibles para determinar el churn se contradicen. Se adopta churn_events como fuente de verdad, con la limitación declarada de una posible subestimación de hasta 35 cuentas.

3. Los cambios de plan no anticipan el abandono. Solo el 8,8 % de las cancelaciones estuvo precedido de un downgrade. La hipótesis inicial queda descartada como predictor principal, lo que obliga a reorientar la búsqueda de señales tempranas.

4. El soporte no parece ser la causa principal del abandono, pero no se descarta. Las métricas de soporte son buenas y la presencia de tickets es prácticamente universal, por lo que no discrimina. La hipótesis se mantiene, reformulada en términos de intensidad relativa y no de mera presencia.

5. El comportamiento de uso es, después del EDA, la vía principal de investigación. Descartados los cambios de plan y debilitada la vía del soporte, las señales tempranas deben buscarse en feature_usage. Las 33 suscripciones sin uso alguno constituyen el punto de partida más evidente.

Variables a construir para el análisis (ninguna está disponible como columna):

- **Recencia (R):** días transcurridos desde el último uso registrado de la cuenta.
- **Frecuencia (F):** número de eventos o días distintos con actividad, por cuenta y período.
- **Valor monetario (M):** ARR agregado de las suscripciones activas de la cuenta.
- **Intensidad:** usage_count y usage_duration_secs agregados por cuenta.
- **Fricción:** error_count acumulado por cuenta.
- **Amplitud de adopción:** número de features distintas utilizadas por la cuenta, sobre las 40 disponibles. Es la hipótesis que conecta directamente con el sistema de recomendación: ¿las cuentas que abandonan adoptan menos funcionalidades que las que permanecen?

Nota sobre el cálculo del ARR por cuenta. Una cuenta puede acumular varias suscripciones a lo largo del tiempo, algunas ya finalizadas. Para el cálculo del ARR actual se suman únicamente las suscripciones activas (aquellas con *end_date* nulo). Incluir las finalizadas inflaría artificialmente el valor de la cuenta.

Fase 2 · Modelado y creación de la base de datos en MySQL.

Cerrada la fase de exploración en Python, que tenía una función diagnóstica, el objetivo de esta segunda fase fue construir la base de datos relacional que contiene los datos de RavenStack. Es el paso que traduce las decisiones tomadas durante el análisis exploratorio en una estructura formal: una base de datos que no solo guarda información, sino que además impide activamente que entren en ella datos incoherentes.

2.1. DDL. Qué es y por qué se separa de los datos.

El archivo `ddl.sql` (Data Definition Language) contiene únicamente las instrucciones que crean la estructura vacía de la base de datos: las 5 tablas, sus columnas, el tipo de dato de cada una y las reglas que las relacionan. No incluye aun los datos. Esta separación entre estructura (DDL) e inserción de los datos es una práctica que permite reconstruir la base de datos entera desde cero ejecutando un único archivo, lo que hace el proyecto reproducible.

El orden de creación de las tablas no ha sido libre. Hay tablas que dependen de otras, por lo que la tabla con la PK de la cual se depende debe ser la que exista primero.

Orden de creación:

1. `accounts` (PK: `account_id`)
2. `subscriptions` (PK: `subscription_id`, FK: `account_id`)
3. `feature_usage` (FK: `subscription_id`)
4. `churn_events` (PK: `churn_event_id`, FK: `account_id`)
5. `support_tickets` (PK: `ticket_id`, FK: `account_id`).

2.2. Decisiones de diseño.

Cada columna se definió eligiendo el tipo de dato que más se ajust al contenido que va a contener, verificado durante el EDA. De esta manera se protege la base de datos frente a errores. A continuación, se resumen las decisiones más relevantes y su justificación.

Decisión	Justificación
<i>Tipos ajustados al dato (SMALLINT, DECIMAL, ENUM...) en lugar de usar VARCHAR/INT para todo</i>	Un tipo ajustado hace que la propia base de datos rechace valores imposibles. Es una validación gratuita que protege futuras cargas.


<i>DECIMAL para los importes monetarios (mrr, arr, refund)</i>	Los números con decimales en coma flotante (FLOAT) guardan aproximaciones y acumulan errores al sumar. En dinero eso es inaceptable: DECIMAL guarda la cifra exacta.
<i>ENUM en categorías cerradas y estables (plan_tier, reason_code, priority...)</i>	Solo admite la lista de valores declarada; cualquier valor extraño se rechaza. En columnas ordinales, los valores se declaran en orden lógico para poder ordenarlas con sentido.
<i>VARCHAR (no ENUM) en categorías que pueden crecer (feature_name, feedback_text)</i>	El catálogo de funcionalidades de un SaaS cambia con el tiempo. Un ENUM obligaría a modificar la tabla con cada valor nuevo.
<i>end_date y satisfaction_score admiten nulos</i>	Sus nulos tienen significado: una suscripción sin fecha de fin está activa; una encuesta sin puntuación es un cliente que no respondió. No son datos que falten.
<i>Clave sustituta (id AUTO_INCREMENT) en feature_usage</i>	El identificador de origen (usage_id) tenía duplicados en eventos distintos y no podía ser clave primaria. Se genera una clave nueva y se conserva usage_id como dato informativo.
<i>churn_flag se conserva aunque no se use en el análisis</i>	Se conserva churn_flag en el modelo por fidelidad a la fuente y trazabilidad de la anomalía documentada, pero se excluye del cálculo de toda métrica.
<i>ENGINE=InnoDB en todas las tablas</i>	Es el único motor que hace cumplir de verdad las claves foráneas. Sin él, se podrían insertar registros huérfanos sin aviso.

2.3. Las claves: primarias y foráneas.

Clave primaria (PRIMARY KEY): es la columna que identifica de forma única cada fila de una tabla. En cuatro de las cinco tablas se usó el identificador que ya venía en los datos (por ejemplo, account_id). En feature_usage no fue posible, porque su identificador de origen estaba duplicado; ahí se creó una clave nueva generada automáticamente por la propia base de datos.

Clave foránea (FOREIGN KEY): es la columna que conecta una tabla con otra. Por ejemplo, cada suscripción guarda el account_id de la cuenta a la que pertenece. La clave foránea obliga a que ese account_id exista realmente en la tabla accounts: si se intenta insertar una suscripción de una cuenta inexistente, la base de datos lo rechaza. Así se garantiza que no queden registros "huérfanos".

Todas las relaciones del modelo son de uno-a-muchos (una cuenta tiene muchas suscripciones, pero cada suscripción pertenece a una sola cuenta), de modo que no fue necesaria ninguna tabla intermedia.



2.4. Diagrama del modelo relacional

La Figura 1 representa el modelo físico de la base de datos una vez creado: las cinco tablas, sus columnas con el tipo de dato asignado y las relaciones que las conectan. Todas las relaciones son de uno-a-muchos. La tabla accounts ocupa la posición central por ser la tabla de la que dependen las demás.




Figura 1. Modelo relacional de RavenStack (diagrama entidad - relación (DER) en MySQL Workbench).

2.5. Ingesta de los datos con Python.

Con la estructura ya creada y vacía, la carga de los datos se realizó desde el mismo notebook de Python, y no mediante el asistente de importación de MySQL. El motivo es la reproducibilidad: la carga por código queda registrada y cualquiera puede repetirla ejecutando el notebook, mientras que una importación manual a base de clics no deja rastro reproducible. Esta decisión, además, cierra de forma coherente el flujo del proyecto: Kaggle → Python → MySQL.

Python → SQLAlchemy → `df.to_sql()` — carga de el CSV con pandas y se escribe en la tabla ya creada.

2.6. Protección de credenciales

La conexión a la base de datos requiere una contraseña. Para que esa contraseña no quede escrita dentro del notebook (y no acabe expuesta al publicar el proyecto), se guardó en un archivo aparte llamado **.env**, que queda fuera del código. El notebook lee la contraseña de ese archivo en tiempo de ejecución. Se conserva dentro la carpeta un documento `.env.example` que sirve para rellenar las credenciales de MySQL del evaluador y las rutas a los datos.

2.7. Verificación final

Tras la carga se comprobó que el número de filas de cada tabla en la base de datos coincidía exactamente con el de los archivos de origen (500, 5.000, 25.000, 600 y 2.000 filas respectivamente). La coincidencia total, unida a la ausencia de errores de clave foránea durante la carga, confirma que la ingesta fue completa y que la integridad entre tablas se respetó.

Verificaciones pendientes para la siguiente fase:

1. Comprobar que todos los importes `mrr_amount = 0` corresponden a suscripciones en periodo de prueba.
2. Interpretar el significado de un evento de uso con contador a 0.
3. Validar que la duración de resolución de los tickets coincide con la diferencia entre las marcas de tiempo de apertura y cierre.

Nota sobre la reutilización de la estructura. El fichero `ddl.sql` se duplicó como `ddl_ravenstack_gemelo.sql`, modificando exclusivamente el nombre de la base de datos (`ravenstack_gemelo`). **Las cinco definiciones de tabla, los tipos, los ENUM y las restricciones de integridad permanecen idénticos.** Ambas bases conviven en el mismo servidor, lo que permite ejecutar la misma consulta contra una y otra y comparar resultados sin ninguna adaptación del código.

Fase 3 · Auditoría de viabilidad del dataset original

3.1. Reformulación de la fase

Esta fase se planteó como el diagnóstico del churn de RavenStack. Su desarrollo la convirtió en otra cosa, y conviene explicar por qué, porque de ello depende la lectura de todo lo que sigue.

Las consultas se escribieron para responder a las cuatro preguntas de negocio formuladas en el apartado 3: cuánto churn hay, quién se va, por qué se va y qué lo anticipa. Ninguna de las cuatro obtuvo respuesta. Lo que se obtuvo, de forma sistemática y por vías independientes entre sí, fueron evidencias sobre la calidad del dato.

Llegado ese punto se adoptó una decisión metodológica: **antes de preguntar por qué se van los clientes hay que establecer si el dataset permite responder a esa pregunta**. La fase se reformula como una auditoría de viabilidad y se cierra con un veredicto sobre el dato, no con un diagnóstico de negocio.

Esta reformulación no es un repliegue ante la dificultad. Es la alternativa a las dos salidas que quedaban, ambas peores: forzar una narrativa explicativa sobre resultados que no la sostienen, o presentar como hallazgos de negocio lo que son defectos de generación.

El recorrido completo se conserva en el script auditoria_datos.sql porque la conclusión solo es defendible si consta el trabajo que la precede: no se concluye que no hay señal por no haberla buscado, sino tras haberla buscado por cuatro vías distintas.

3.2. Verificaciones previas

El análisis exploratorio dejó tres cuestiones abiertas que condicionaban el uso de las columnas implicadas. Se resuelven antes de construir ninguna métrica.

Los importes mrr_amount = 0 corresponden a suscripciones en período de prueba.

El cruce con is_trial devuelve únicamente dos categorías: 4.222 suscripciones de pago con MRR positivo y 778 suscripciones en trial con MRR nulo. No aparece ninguna combinación anómala. La hipótesis queda confirmada, y con ella la decisión operativa de filtrar is_trial = 0 en todo cálculo de ingresos medios: mezclar ambas poblaciones hundiría la media.

Los eventos con usage_count = 0 son residuales. Solo 2 registros sobre 25.000. Volumen despreciable que no afecta a ninguna agregación de intensidad. No se adopta ninguna medida.

Las 33 suscripciones sin uso pertenecen a 32 cuentas distintas. Algunas corresponden a cuentas de tamaño considerable. El EDA las había señalado como el segmento de riesgo extremo del dataset, hipótesis que se contrasta en el apartado 3.5.

3.3. Definición operativa del churn

El análisis exploratorio estableció que las dos fuentes disponibles para determinar el abandono se contradicen, y adoptó churn_events como fuente de verdad. Quedaba por resolver un problema interno de esa tabla: contiene reactivaciones, de modo que no todo evento registrado equivale a un abandono.

Regla adoptada. Los eventos de cada cuenta se ordenan por fecha descendente mediante una función de ventana (ROW_NUMBER() OVER (PARTITION BY account_id)), y se retiene únicamente el más reciente. Si ese último movimiento es una reactivación, la cuenta no computa como baja: se fue y volvió. Si es una cancelación sin reactivación posterior, computa.

El resultado modifica la cifra de partida del proyecto:

Medida	Cuentas	% sobre 500
Cuentas con al menos un evento registrado	352	70,4 %
Cuentas cuyo último movimiento es una reactivación	37	7,4 %
Longo churn real	315	63,0 %

Sobre esta regla se construye la vista estado_churn_cuenta, que devuelve una fila por cada una de las 500 cuentas con su estado resuelto y el contexto de su último movimiento (fecha, motivo e importe reembolsado). Todas las consultas posteriores consumen de ella la definición de churn.

Hallazgo: trece cuentas describen una secuencia imposible. La verificación de la vista detecta 13 cuentas cuyo único evento registrado está marcado como reactivación. Una cuenta no puede reactivarse sin haberse dado de baja previamente. No se trata de una ambigüedad de interpretación sino de una secuencia lógicamente imposible, y constituye la primera evidencia de que el generador del dataset no impuso restricciones de orden entre eventos.

Precisión necesaria sobre el 63 %. Esta cifra no es una tasa de churn en sentido estricto: es una proporción acumulada sobre un período de veinticuatro meses, calculada sobre cuentas con tiempos de exposición muy desiguales. Una tasa de churn requiere un período de referencia fijo y una población en riesgo homogénea, condiciones que este dato no cumple. Se reporta como magnitud descriptiva y no como indicador comparable con los estándares del sector.

3.4. Primera vía: las características de la cuenta

Si el abandono tuviera estructura, debería concentrarse en algún tipo de cuenta: un plan, un sector, un país o un tamaño determinado.

El tamaño de la cuenta no discrimina. La comparación de *seats* y ARR medio entre cuentas dadas de baja y cuentas activas no arroja diferencia apreciable. El churn es indiferente a la magnitud del cliente.

Nota sobre la fiabilidad de seats. La comprobación previa reveló que la suma de *seats* de las suscripciones de una cuenta supera ampliamente el máximo de 163 registrado en accounts. La causa es la desincronización ya documentada: las suscripciones extintas conservan sus licencias y estas se acumulan. Se adopta accounts.seats como medida de magnitud, por coherencia con el EDA.

El plan contratado no discrimina. Los tres planes orbitan la tasa base sin que ninguno se separe de forma apreciable.

La industria y el país tampoco. El rango entre sectores es algo mayor que entre planes, pero insuficiente para sostener una predicción. En cuanto al país, la mayoría de los grupos son demasiado pequeños para calcular una tasa con sentido; Estados Unidos, el único grupo grande, presenta un 70,8 % que coincide con la base.

Conclusión de la primera vía. Ninguna categoría presenta un churn distinto del global. Las variables que describen lo que la cuenta es no explican el abandono.

3.5. Segunda vía: el comportamiento de la cuenta

Descartadas las características estructurales, la búsqueda se traslada a lo que la cuenta *hace*. Es la vía que el EDA había señalado como principal, y la que sostenía el sistema de recomendación propuesto.

Ninguna de las tres dimensiones del modelo RFM existe como columna: fue necesario construirlas por agregación sobre feature_usage, con el doble salto de tablas que impone el modelo relacional.

Ninguna de las tres dimensiones separa a los grupos. Los promedios de recencia, frecuencia y valor monetario son prácticamente idénticos entre cuentas dadas de baja y cuentas activas. Este resultado es el más grave del apartado, y merece detenerse en él. Que la frecuencia o el valor no discriminen es un hallazgo posible: hay negocios donde el abandono no guarda relación con la intensidad de uso. Pero **que la recencia no discrimine no es un hallazgo posible.**

Una cuenta que canceló hace ocho meses no puede tener la misma recencia de uso que una cuenta activa, salvo que siga utilizando el producto después de haberse ido. Esta anomalía se investiga específicamente en el apartado 3.7.

La amplitud de adopción tampoco discrimina. El número de funcionalidades distintas utilizadas por cuenta es equivalente en ambos grupos. Era la hipótesis que conectaba directamente con el sistema de recomendación —si quienes abandonan adoptan menos funcionalidades, recomendárselas es una acción de retención— y queda sin sustento.

Comprobación adicional. Se verificó si la amplitud de funcionalidades accesibles depende del plan contratado, como sucedería en cualquier SaaS real. Las 40 funcionalidades aparecen en los tres planes por igual: el dataset no modeló esa dependencia.

El único segmento con dirección coherente. De las 32 cuentas con suscripciones sin ningún uso registrado, 25 se dieron de baja y 7 permanecieron. Es la única señal del dataset que apunta en la dirección esperada, y resulta insuficiente por dos motivos: descansa sobre 32 cuentas de 500, base muestral demasiado estrecha para sostener un sistema de detección; y describe un comportamiento tan extremo —contratar y no usar nunca el producto— que su valor predictivo es trivial. Un sistema que solo detecta a quien nunca se conectó no aporta anticipación.

3.6. Tercera vía: las causas declaradas

Si el comportamiento observado no explica el abandono, cabe preguntarse si lo explican los motivos que el propio cliente declara al marcharse.

No existe una causa dominante. El reparto de `reason_code` es prácticamente uniforme entre las seis categorías. Ninguna razón destaca sobre las demás, lo que resulta coherente con la ausencia de señal hallada en los apartados anteriores.

Prueba de coherencia interna. Se contrastó lo declarado con lo observado: las cuentas que alegan falta de funcionalidades como motivo de baja, ¿son efectivamente las que menos funcionalidades utilizaban? El resultado es negativo: su amplitud de adopción media es equivalente a la del resto.

Implicación. El motivo declarado y el comportamiento registrado son independientes entre sí. En un conjunto de datos coherente cabría esperar alguna correspondencia, aunque fuera débil, entre lo que el cliente dice y lo que el cliente hizo. Su ausencia completa indica que `reason_code` se asignó sin relación con el resto de las tablas.

3.7. Cuarta vía: la estructura temporal

Las tres vías anteriores documentan variables sin poder discriminante. Esta documenta algo distinto y de mayor gravedad.

El churn no depende del tiempo de exposición. El análisis por cohortes de alta muestra que los días de observación se desploman cohorte tras cohorte —cuanto más tarde se dio de alta un grupo, menos tiempo se ha podido observar— mientras que el porcentaje de churn sube y baja sin relación alguna con ellos. Un churn acumulado solo puede crecer con el tiempo de observación: una cohorte observada durante 476 días tiene necesariamente que haber perdido más cuentas que una observada durante 41. No es una expectativa de negocio, es una imposibilidad aritmética.

La escalada del último trimestre no se explica por el crecimiento. La distribución mensual de bajas presenta un salto abrupto: de entre 1 y 5 bajas mensuales durante 2023 a entre 27 y 86 en el cuarto trimestre de 2024. La hipótesis inmediata es que hubiera más clientes expuestos. Los datos la descartan: la base de clientes se multiplicó por 2,2 entre 2023 y 2024, mientras que las bajas mensuales se multiplicaron por 17,2.

Descarte de la explicación de calendario. Antes de atribuir el fenómeno a un defecto de generación procedía descartar una explicación de negocio perfectamente plausible: un efecto de calendario. Si las suscripciones cerradas en diciembre fueran mayoritariamente de facturación anual, el pico correspondería a vencimientos concentrados a cierre de ejercicio y constituiría un patrón normal.

<i>Facturación Suscripciones cerradas en dic-2024</i>	
<i>Anual</i>	104
<i>Mensual</i>	89

El reparto es de 54 % frente a 46 %, [**contrastar con la composición global de billing_frequency en la tabla completa**]. No existe la concentración de contratos anuales que exigiría la hipótesis de calendario: la composición de diciembre reproduce la del conjunto. **La explicación de calendario queda descartada.**

La consulta revela además una anomalía adicional que no se buscaba. Las 193 suscripciones cerradas en diciembre de 2024 representan cerca del 40 % de las 486 cancelaciones registradas en los veinticuatro meses del período. Si los cierres se distribuyeran de forma regular cabría esperar unas 20 mensuales. La concentración en el último mes disponible es característica de un truncamiento de generación: las fechas se asignaron dentro de una ventana y se acumularon contra su límite superior.

Consulta decisiva: uso del producto posterior a la fecha de baja. Todo sistema de alerta temprana presupone que la actividad cesa cuando la cuenta se da de baja. En RavenStack esa presuposición es además una certeza del modelo de negocio: no existe modalidad gratuita, de modo que una cuenta cancelada no puede seguir utilizando el producto (véase el apartado 2.1). Si lo hace, el eje temporal carece de sentido.

Métrica	Valor
Eventos de uso posteriores a la fecha de baja	2.934
Cuentas afectadas	264
Proporción sobre las 315 cuentas dadas de baja	83,8 %

Hallazgo: la secuencia temporal del dataset no es coherente. Cinco de cada seis cuentas dadas de baja registran actividad con posterioridad a su cancelación, en un volumen que alcanza el 12 % de toda la tabla feature_usage.

Implicación. Este resultado no describe ningún comportamiento de negocio: es imposible bajo las reglas del producto. La única lectura disponible es que las fechas de uso se generaron con independencia de las fechas de cancelación, sin ninguna restricción de orden entre ambas tablas.

La consecuencia alcanza al núcleo del proyecto. **Las variables de recencia, enfriamiento y degradación de uso carecen de significado en este conjunto de datos.** Y con ellas, la cuarta pregunta de negocio y el sistema de recomendación que se apoyaba en ella.

Este hallazgo explica retroactivamente el resultado del apartado 3.5: la recencia no separaba a los grupos porque las cuentas dadas de baja siguen registrando uso hasta el final del período, igual que las activas.

3.8. Veredicto de la auditoría

La auditoría se cierra con seis evidencias convergentes, tres procedentes del análisis exploratorio en la Fase 1 y tres evidencias de esta Fase 3 (que pretendía ser el análisis de churn y ha acabado siendo una auditoría):

Evidencia	Origen
1 Dos fuentes de churn contradictorias e irreconciliables (277 + 35 cuentas en conflicto)	Fase 1
2 Los cambios de plan no anticipan la baja: el upgrade previo (20,5 %) duplica al downgrade (8,8 %)	Fase 1
3 La satisfacción del cliente nunca desciende de 3 en una escala de 1 a 5	Fase 1
4 Trece cuentas cuyo único evento registrado es una reactivación: secuencia imposible	Fase 3 - 3.3
5 Ninguna variable estructural discrimina: plan, industria, país, tamaño	Fase 3 - 3.4
6 Ninguna variable de comportamiento discrimina, ni siquiera la recencia	Fase 3 - 3.5
7 El motivo declarado es independiente del comportamiento observado	Fase 3 - 3.6
8 El 83,8 % de las cuentas dadas de baja registra uso posterior a su cancelación	Fase 3 - 3.7

Las siete primeras describen variables sin poder discriminante y anomalías locales. La octava es de naturaleza distinta: **no es una columna defectuosa, es la relación temporal entre dos tablas la que carece de sentido**. Y sobre esa relación descansaba la pregunta central del proyecto.

Decisión adoptada: se cierra el diagnóstico de churn sobre el dataset original. De las diecinueve consultas planificadas para esta fase se ejecutaron las necesarias para alcanzar el veredicto. Prolongar el análisis con las restantes habría producido más resultados planos sin alterar la conclusión, e incurriría precisamente en el error que esta auditoría documenta: forzar una narrativa sobre datos que no la sostienen.

Conclusión: no existe señal de churn utilizable en el dataset original de RavenStack.

Esta conclusión se acompaña de la valoración que en su momento cerró la fase, y que sigue siendo exacta: *la generalización de un sistema de recomendación a toda la base de clientes requeriría datos con señal de comportamiento, ausente en este dataset.*

3.9. Limitación de la conclusión y transición

Un resultado negativo admite dos interpretaciones que conviene no confundir:

- que la señal no exista en los datos (**verdadero negativo**);
- que la señal exista y el procedimiento analítico empleado no haya sabido detectarla (**falso negativo**).

Nada de lo expuesto permite descartar la segunda. Se trata de una objeción legítima y dirigida al núcleo del trabajo: el mismo conjunto de consultas que no encuentra nada en RavenStack podría no encontrar nada en ningún sitio, y en tal caso lo que esta fase documentaría no sería una propiedad del dato sino una limitación del analista.

Distinguir ambos casos exige un conjunto de datos en el que se conozca la verdad de antemano, condición incompatible con cualquier dato real. La Fase 4 se dedica íntegramente a construirlo y a resolver la cuestión.

3.10. Nota metodológica: sobre el criterio para detenerse

La decisión de cerrar una fase sin haber ejecutado el plan completo merece justificarse, porque la alternativa —seguir consultando hasta encontrar algo— es la que produce los falsos hallazgos.

El criterio aplicado fue el siguiente: mientras las evidencias describían variables sin poder discriminante, el análisis continuaba, porque una variable plana no impide que otra sea informativa.

En el momento en que la evidencia dejó de ser sobre una variable y pasó a ser sobre la **relación entre tablas**, el criterio cambió: ninguna consulta adicional puede reparar un eje temporal incoherente, porque todas lo atraviesan.

Ejecutar las trece consultas restantes habría aumentado el volumen del trabajo sin aumentar su fundamento. Documentar por qué no se ejecutaron es, a efectos de rigor, más informativo que ejecutarlas.

Fase 4 · Banco de pruebas: validación de la sensibilidad del método

4.1. La pregunta que resuelve esta fase

¿No hay señal de churn en RavenStack, o el procedimiento analítico empleado es incapaz de detectarla?

Responder exige un conjunto de datos en el que **se conozca de antemano la verdad**: si el método se aplica sobre datos donde consta que existe una relación determinada y la recupera, queda demostrado que posee sensibilidad. Y si posee sensibilidad, su silencio sobre RavenStack es informativo.

Ese conjunto no existe entre los datos públicos disponibles, porque la condición que se le exige —conocer la verdad de antemano— es incompatible con un dato real. Se construye, por tanto, un **gemelo sintético**: un conjunto de datos generado sobre el esquema de RavenStack, con una señal de churn inyectada deliberadamente y de magnitud conocida.

4.2. Advertencia epistemológica

Esta es la fase que más fácilmente puede malinterpretarse, y conviene delimitar con precisión qué demuestra y qué no.

Cualquier relación que el análisis encuentre en el gemelo fue introducida en él por la autora de este trabajo. Recuperarla no constituye un descubrimiento sobre el comportamiento de los clientes de ninguna empresa. Afirmar «el churn de RavenStack se explica por la degradación del uso» a partir del gemelo sería un razonamiento circular: se estarían recuperando los parámetros del generador. Lo que el gemelo permite afirmar es de otro orden: en un entorno controlado donde se inyectó una relación de magnitud conocida, el procedimiento analítico la recuperó.

Es una afirmación sobre el método, no sobre el negocio. El gemelo es un instrumento de medida del análisis, no una fuente de conclusiones.

4.3. Estructura causal inyectada

El generador no asigna el churn de forma arbitraria ni lo hace depender directamente de las variables observables. Se introduce una variable latente —la *salud* de la cuenta— que **no figura en ninguna tabla** y que causa simultáneamente el comportamiento observable y la probabilidad de abandono:

salud de la cuenta (latente, no observable)

- └─> amplitud de adopción de funcionalidades
- └─> intensidad de uso y su degradación previa a la baja
- └─> errores técnicos registrados
- └─> fricción de soporte (volumen, tiempos, escalados, satisfacción)
- └─> contexto comercial (renovación automática, downgrades)
- └─> probabilidad de churn

Esta estructura reproduce la situación real de un analista: la causa no es observable y solo se accede a ella a través de sus manifestaciones. El análisis no descubre la salud de la cuenta; descubre sus **indicadores observables**.

Variables de control. El país, la industria y el plan contratado se generaron **sin ninguna influencia sobre el churn**. Su presencia es deliberada: un conjunto de datos en el que toda variable resulte predictiva es tan inverosímil como uno en el que ninguna lo sea, y obliga al análisis a discriminar señal de ruido en lugar de limitarse a encontrar correlaciones.

4.4. Fidelidad al conjunto original

El gemelo replica el esquema, los volúmenes y —deliberadamente— los defectos documentados en la Fase 1, de modo que las decisiones de limpieza y modelado adoptadas siguen siendo aplicables sin modificación:

Elemento	Original	Gemelo
Esquema, tipos y claves foráneas	--	Idénticos
Identificadores duplicados en usage_id	21 (42 filas)	21 (42 filas)
Suscripciones sin uso registrado	33	33
Nulos legítimos en end_date	Sí	Sí
Nulos en satisfaction_score y feedback_text	Sí	Sí
Desincronización de seats entre tablas	Sí	Sí
Contradicción churn_flag vs churn_events	75 / 35 / 277	29 / 35 / 111
Tabla accounts	--	Idéntica salvo churn_flag

La conservación de la tabla accounts tiene una consecuencia relevante: todo el análisis exploratorio de esa tabla realizado en la Fase 1 (distribución de *seats* con media 20,56 y mediana 15, concentración geográfica en Estados Unidos, cardinalidad de las variables categóricas) sigue siendo válido sin modificación.

#	Modificación	Justificación
1	Las suscripciones de las cuentas dadas de baja se cierran en torno a su fecha de churn.	En el original ambas tablas estaban desconectadas y el revenue churn resultaba incalculable.
2	<i>satisfaction_score</i> recorre el rango completo 1–5	Sin puntuaciones bajas la variable carece de capacidad discriminante.
3	La tasa de escalado asciende del 4,75 % a ~13 %	Necesita recorrido para discriminar.
4	<i>reason_code</i> deja de repartirse uniformemente	Se correlaciona con los indicadores, de modo que el análisis de causas admite respuesta.
5	<i>feedback_text</i> es coherente con <i>reason_code</i>	En el original ambas variables estaban desacopladas.
6	Ninguna reactivación figura como primer evento de una cuenta	Corrige una incoherencia lógica del original.
7	La tasa de churn desciende del 63 % (315 cuentas al 23,8 % (119 cuentas)	Una tasa acumulada del 60-70 % no es verosímil en un negocio de suscripción.
8	<i>subscriptions</i> pasa de 5.000 a 1.164 filas (media de 2,33 por cuenta)	Diez suscripciones simultáneas por cuenta elevaban el ARR agregado a cifras inverosímiles.
9	<i>churn_events</i> pasa de 600 a 238 filas	Se deriva del número de cuentas dadas de baja, conservando la proporción de eventos por cuenta.

4.5. Verificación de coherencia temporal

La consulta que cerró la auditoría del original (Fase 3, C5) se ejecuta sin modificación sobre el gemelo:

Métrica	RavenStack	Gemelo
Eventos de uso posteriores a la baja	2.934	0
Cuentas afectadas	264 (83,8 %)	0

4.6. Validación de sensibilidad

Se generaron **tres variantes** del gemelo, idénticas salvo en la magnitud de la señal inyectada:

Variante	Señal	Función
Control	0,0	Réplica sin señal. Debe reproducir la planitud de RavenStack
Débil	0,5	Umbral de detección
Principal	1,0	Escenario de trabajo del proyecto

Sobre cada variante se aplicó el mismo procedimiento de puntuación de riesgo, con validación temporal (los indicadores se calculan con datos anteriores a una fecha de corte y se observa el abandono en los 180 días siguientes), replicado sobre tres semillas aleatorias y dos fechas de corte distintas.

La métrica es el **lift**: cuántas veces más abandono concentra el 25 % de cuentas peor puntuadas respecto de la tasa media. Un lift de 1,0 equivale al azar.

Señal inyectada	Lift medio	Desviación	Cuentas evaluables
0,0 (control)	0,99	0,32	230
0,5 (débil)	2,09	0,28	234
1,0 (principal)	2,42	0,61	238

Lectura del resultado. Sobre la variante de control, el procedimiento no detecta absolutamente nada: un lift de 0,99 es indistinguible del azar. Sobre las variantes con señal, la detecta con holgura. El método, por tanto, **no produce hallazgos donde no los hay ni deja de producirlos donde los hay**.

Conclusión de la fase. El resultado negativo obtenido sobre RavenStack en la Fase 3 es un **verdadero negativo**: la ausencia de señal es una propiedad del conjunto de datos, no una limitación del procedimiento analítico empleado.

4.7. Errores de diseño detectados durante la validación

El banco de pruebas fue a su vez sometido a comprobación, y dos versiones iniciales resultaron defectuosas. Se documentan porque ilustran el criterio aplicado y porque un instrumento de medida que no se valida no es un instrumento de medida.

Sesgo de supervivencia autoinducido. La primera versión del generador hacía depender de la salud de la cuenta no solo *si* abandonaba, sino *cuándo*: las cuentas sanas se marchaban más tarde.

La consecuencia fue que las cuentas vivas en cualquier fecha de corte constituían una muestra sesgada hacia la buena salud, y la señal se desvanecía precisamente en la población que el sistema de alerta debe atender.

El *lift* resultante fue de 0,9, inferior al azar. Corregido: la salud determina si la cuenta abandona, no en qué momento.

Ventana de degradación insuficiente. La degradación de uso comenzaba 90 días antes de la baja, mientras que al sistema se le exigía anticipación a 180 días. Ningún procedimiento puede anticipar con seis meses una señal que se origina tres meses antes del suceso. La ventana se amplió a 210 días.

Un tercer error correspondió al análisis y no al generador: **la amplitud de adopción sin normalizar mide antigüedad, no adopción.** Una cuenta con más tiempo de vida acumula más funcionalidades distintas por el mero transcurso del tiempo. Sin normalizar, la variable entraba en la puntuación de riesgo con el signo invertido y degradaba el resultado.

Fase 5 · Diagnóstico del churn

Validada la sensibilidad del procedimiento, se aplica el diagnóstico completo sobre el gemelo sintético. Se emplean las vistas: `estado_churn_cuenta` y `metrica_por_cuenta`.

Código de las vistas creadas en esta fase: [03_documento_vistas.sql](#). *NOTA: sobre la métrica por cuenta: 'recencia': Esta columna ('recencia') se calcula contra una fecha fija (31-12-2024). Para una cuenta activa cuánto hace que no da señales de vida. Pero para una cuenta que se dio de baja cuenta los días transcurridos tras su baja (no recencia).*

Antes de iniciar el diagnóstico se ejecutan 4 verificaciones sobre el conjunto de datos.

BLOQUE 0. PUNTO DE PARTIDA.

- 1) La primera confirma que las 1.164 suscripciones se reparten en solo dos categorías coherentes: 1.002 de pago con MRR positivo y 162 en período de prueba con MRR nulo, sin ninguna combinación anómala, lo que autoriza a emplear `mrr_amount` como métrica de ingresos filtrando previamente los trials.
- 2) La segunda contrasta las dos fuentes de churn disponibles y revela que 133 cuentas (el 26,6 %) discrepan entre sí: 94 se dieron de baja sin que `churn_flag` las detecte y 39 aparecen marcadas sin haberse ido, de modo que haber adoptado esa columna como fuente habría clasificado erróneamente a una de cada cuatro cuentas y justifica la decisión, tomada en la Fase 3, de emplear `churn_events` como fuente única de verdad.

- 3) La tercera fija las cifras de partida sobre las que se interpretará todo lo que sigue: 119 cuentas dadas de baja frente a 381 activas.
- 4) La cuarta repite la consulta que cerró la auditoría del conjunto original y devuelve cero eventos de uso posteriores a la fecha de cancelación, frente a los 2.934 detectados entonces, confirmando que la relación temporal entre las tablas es coherente y que las métricas de recencia y degradación pueden construirse sobre ella.

BLOQUE 1. ANÁLISIS DEL CHURN.

Se emplea también el mismo código SQL desarrollado en la Fase 3, ejecutado sobre la base de datos: ravenstack_gemelo. Los resultados de cada consulta se trasladan a un documento Excel para transformarlos en imagen, evitando la captura de pantalla. En algunas consultas, se acompaña el formato tabla con un gráfico para mejor visualización.

Pregunta 1 — Cuantificación: ¿cuánto churn hay y cuánto cuesta?

Consulta 1. Churn por cohorte de antigüedad.

La primera consulta del diagnóstico es la primera precisamente porque se busca verificar que el eje temporal del conjunto de datos es coherente antes de construir nada sobre él.

año_alta	trimestre_alta	cuentas	bajas	porcentaje_churn	días_observacion_media
2023	1	55	21	38.18	555
2023	2	54	16	29.63	529
2023	3	53	18	33.96	415
2023	4	65	19	29.23	347
2024	1	56	17	30.36	264
2024	2	65	9	13.85	214
2024	3	72	10	13.89	128
2024	4	80	9	11.25	47
		500	119		

Se ha agrupado las cuentas por trimestre de alta y el porcentaje de bajas acumuladas de cada cohorte con los días de observación de que ha dispuesto.

El razonamiento es sencillo: una cuenta no puede darse de baja antes de existir, y la cohorte del Q1 de 2023 acumula 555 días de exposición al riesgo de churn frente a los 47 días de la del Q4 de 2024. Por este motivo, un churn acumulado debe mostrar ambas magnitudes para entenderse mejor.

Los resultados confirman esa relación: el porcentaje de churn descende de forma sostenida desde el 38,18% hasta el 11,25% conforme se va estrechando la ventana de observación.


El eje temporal es, por tanto, coherente en este sentido y el análisis puede apoyarse en él (a diferencia del conjunto de datos original, que devolvía porcentajes que variaban sin relación alguna con el tiempo de exposición, algo imposible aritméticamente en un churn acumulado).

Una precaución de lectura: sería erróneo concluir que la retención ha mejorado con el tiempo, esta consulta mide un intervalo temporal distinto para cada cohorte y por este motivo no son comparables entre sí.

Consulta 2. Distribución temporal a nivel mensual de las bajas y las altas.

Esta consulta se divide en dos partes de código (consulta 2a y consulta 2b) para poder contextualizar el hecho de que el aumento de bajas se pueda explicar a tener una mayor base de clientes. Desde las dos tablas se construye un gráfico en Excel para que el lector entienda mucho mejor y de un vistazo los resultados de esta consulta.

Una precaución de lectura: El crecimiento de las bajas puede parecer mayor que el de las altas: se trata de un hecho natural dado que el negocio a principios de 2023 era joven y acumulaba solo 17 altas.



Resultados: Vemos que las bajas muestran una serie es **un goteo continuo, no un episodio concentrado**. No hay un mes que concentre las bajas. El crecimiento en términos absolutos es compatible con una base que crece y madura. Eso descarta que el churn responda a un suceso puntual y apunta a algo estructural.

Consulta 3. Tiempo de vida hasta la baja.

Esta consulta se distribuye también en dos líneas de código (consulta 3a y consulta 3b). El propósito es ver el tiempo de vida de las 119 cuentas que se dieron de baja, para entender si las cuentas se fueron pronto o se quedaron durante mucho tiempo.

En la **parte 3a** se ha dividido las cuentas que fueron baja (119) entre 4 grupos iguales, ordenando las cuentas por días de vida.

cuartil	cuentas	dias_desde	dias_hasta	Ventana temporal
1	30	15	93	78
2	30	94	187	93
3	30	189	344	155
4	29	355	555	200

Resultado: El análisis del tiempo de vida de las 119 cuentas dadas de baja revela una distribución fuertemente asimétrica: el abandono se produce entre los 15 y los 555 días desde el alta. El reparto por cuartiles resulta explica que las 30 primeras bajas se concentran en una ventana de 78 días, mientras que el último cuartil se extiende a lo largo de 200, lo que indica que el ritmo de abandono se desacelera conforme la cuenta madura.

La **parte 3b** pretende complementar la lectura anterior, analizando las cuentas que se dieron de baja por tramos de tiempo y una normalización de densidad de bajas por anchura de cada intervalo del tramo, dado que se trata de anchuras de tiempo diferentes y no puede interpretarse el porcentaje de cuentas que caen en ese tramo de tiempo como un hallazgo por sí solo.

tramo_vida_cuenta	cuentas	porcentaje	densidad
a. 30 días	10	8.4	8,4%
b. 31-90 días	19	15.97	8,0%
c. 91-180 días	29	24.37	8,1%
d. 181-365 días	34	28.57	4,6%
e. Más de 1 año	27	22.69	3,6%

Resultado: El análisis por tramos, una vez normalizada la densidad de bajas por la anchura de cada intervalo muestra un patrón que la distribución bruta ocultaba: durante los seis primeros meses el riesgo de abandono permanece constante en torno al 8 %.

La densidad descende a partir del sexto mes hasta situarse en el 3,6 %, si bien esta caída no admite una lectura directa: para aparecer en el tramo «más de 1 año» una cuenta tiene que llevar más de 365 días activa. Las 80 cuentas que entraron en el último trimestre de 2024 no pueden estar ahí porque no les ha dado tiempo. Los tramos largos solo pueden contener cuentas antiguas, así que su densidad sale baja en parte porque hay menos candidatos, no porque la gente aguante más.

Consulta 4. Coste administrativo del churn.

bajas	con_reembolso	media_por_baja	media_por_reembolso	reembolso_minimo	reembolso_maximo	total_reembolso
119	33	16.26	58.62	11.65	180.41	1934.36

Hay 119 bajas registradas y 33 de ellas obtuvieron un reembolso junto con la cancelación.

Resultado: La **media por baja** es el coste esperado por cliente perdido: 16,26\$. Se calcula en base a las 119 cuentas que hicieron baja. La **media por reembolso** se calcula en base a las 33 cuentas que obtuvieron un reembolso. Es lo esperado cuando toca pagar: 58,62\$.

Reembolso mínimo: 11,65\$. **Reembolso máximo:** 180,41\$.

Total reembolsado: 1.934,36\$ por 119 clientes perdidos.

Una precaución de lectura: la cifra monetaria de 1.934,36\$ no responde por sí sola a la pregunta «¿cuánto cuesta el churn?». A lo que responde esta cifra es al gasto administrativo del churn. El **revenue churn acumulado es la pérdida real** y se calcula con la facturación recurrente que esas 119 cuentas ya no van a generar nunca. Por eso precisamente, se responde en la siguiente consulta.

Consulta 5. Revenue churn acumulado.

(Esta consulta estaba bloqueada en RavenStack original porque las suscripciones canceladas no tenían fecha de cierre).

cuentas_churn	cuentas_sin_valor	revenue_perdido	revenue_actual	pct_revenue_churn
119	3	6210576	21745224	22.22

De las 119 cuentas dadas de baja, existen 3 cuentas que carecen de valor monetario asignado. Corresponden a suscripciones iniciadas en los quince días previos a la cancelación, que quedan fuera de la ventana de referencia empleada por la vista. El importe afectado equivale al 2% del ARR perdido y no altera ninguna conclusión.

Resultado: El logo churn de RavenStack (gemelo), es decir, la cartera de clientes perdidos es del 23,80%. Su revenue churn, es decir, el valor monetario acumulado de las cuentas que se dieron de baja y que se deja de percibir de esas cuentas, es de un 22,22%. Siendo que los dos porcentajes son parecidos (teniendo en cuenta que el ARR perdido está subestimado en tres cuentas sin valor asignado), podemos concluir que no se van cuentas grandes, sino que el tamaño de la cuenta apenas influye en el abandono.

Pregunta 2 — Caracterización: ¿Se van los logos pequeños o los ingresos grandes?

Consulta 6. Tamaño de las cuentas que se van frente a las que se quedan.

Esta consulta la he dividido en dos partes o 'queries':

Para poder segmentar las cuentas por tamaño por sus cortes naturales las he dividido en usando la función NTILE(). Esta función obliga a que los grupos partidos tengan exactamente las mismas cuentas: se reparten las 500 cuenta en 4 grupos iguales, por lo que cada grupo tiene 125 cuentas. El resultado que obtengo es una repartición equitativa en número de cuentas pero con rangos diferentes de seats, que me han servido en la segunda query para clasificarlas en cuentas 'pequeñas', 'medianas', 'grandes' y 'muy grandes'.

grupo	cuentas	desde_num_seats	hasta_num_seats
1	125	1	5
2	125	5	15
3	125	15	28
4	125	28	163

El grupo 1 son cuentas de entre 1 y 5 seats. – 'Cuentas pequeñas'

El grupo 2 son cuentas de entre 5 y 15 seats. – 'Cuentas medianas'

El grupo 3 son cuentas de entre 15 y 28 seats. – 'Cuentas grandes'

El grupo 4 son cuentas de entre 28 y 163 seats. – 'Cuentas muy grandes'

clasificacion_tamaño	total_cuentas	cuentas_churn	tasa_churn
a. Cuentas pequeñas	126	35	27.78
b. Cuentas medianas	134	25	18.66
c. Cuentas grandes	116	28	24.14
d. Cuentas muy grandes	124	31	25
	500	119	23.895

Interpretación del método: Yo misma me preguntaba por qué usando la función NTILE() obtenemos 125 cuentas en cada grupo con sus respectivos tramos de tamaño y al clasificarlas con CASE respetando los rangos el número de cuentas se distribuye diferente.

La explicación es que NTILE tiene una regla estricta: **los cuatro grupos deben tener el mismo número de filas**. Para este caso, cuando llega a la frontera y se le acaba el cupo, corta aunque esté partiendo cuentas idénticas y enviándolas al siguiente grupo. Es decir, distribuye las filas de forma arbitraria cuando hay empates, mientras que la expresión CASE mantiene los valores empatados juntos en el mismo grupo.

De esta manera se fijan para que las cuentas de igual tamaño queden siempre en el mismo tramo. De ahí que los grupos resultantes no sean exactamente iguales en número.

Resultado: Las cuatro tasas de churn oscilan entre el 18,66 % y el 25,00 %, todas ellas en torno a la tasa global del 23,89 %, y sin describir ninguna progresión: el abandono baja en el segundo tramo y vuelve a subir en los dos siguientes. El tamaño de la cuenta, medido en número de licencias, no discrimina el churn, resultado coherente con la equivalencia ya observada entre el revenue churn (22,22 %) y el logo churn (23,89 %).

Consulta 7. Concentración del valor.

Para evitar confiar demasiado en el promedio de la consulta anterior, vamos a ver si hay existen cuentas que supongan un riesgo real de pérdida para el negocio (en términos monetarios). Para ello, ordeno las cuentas de mayor a menor facturación y las parto en 10 grupos iguales para observar que porcentaje del ARR total del negocio aporta cada grupo. De paso, se calcula también el porcentaje de churn de esos grupos, para ver si el abandono se concentra donde duele más o si no tiene patrón:

grupo	cuentas	valor_arr	pct_valor_arr	cuentas_churn	tasa_churn	pct_arr_perdido
1	49	8868696	31.72	11	22.45	29.36
2	49	5283708	18.9	8	16.33	14.19
3	49	3831792	13.71	12	24.49	15.05
4	49	2946828	10.54	16	32.65	16.24
5	49	2323284	8.31	9	18.37	6.93
6	48	1780272	6.37	13	27.08	7.93
7	48	1351620	4.83	5	10.42	2.29
8	48	922740	3.3	17	35.42	5.11
9	48	539760	1.93	15	31.25	2.58
10	48	107100	0.38	10	20.83	0.32
10	485	27955800	99.99	116	23.929	100

Hallazgo accionable: El riesgo es uniforme pero el daño no. La facturación en RavenStack está muy concentrada Como la probabilidad de cancelar es la misma en toda la cartera, el impacto económico recae de forma desproporcionada sobre las cuentas grandes.

Segmento de facturación	Cuentas perdidas	% de la facturación perdida
10% cuentas más grandes	11	29,4%
30% cuentas más pequeñas	42	8,0%

Las 11 cuentas grandes suponen casi el 30% de todo el ARR perdido, mientras que las 42 cuentas pequeñas apenas representan el 8% del ARR perdido. La tasa de churn, en cambio, no guarda relación con esa jerarquía: oscila entre el 10,42 % y el 35,42 % sin describir ninguna tendencia, y las diferencias observadas se sitúan dentro del margen de variación esperable para grupos de 49 cuentas, por lo que no cabe atribuirles significado.

La implicación operativa es directa: cualquier esfuerzo de retención que trate a todos los clientes por igual está mal dirigido por construcción: **la priorización de los esfuerzos de retención no debe apoyarse en el riesgo de fuga sino en el valor expuesto, concentrando la atención en el tercio superior de la cartera.**

Pregunta 3 — Causas: ¿por qué se van y cuánto cuesta cada motivo?

Consulta 8. Distribución de los motivos de cancelación.

Esta consulta pretende visibilizar el porcentaje de cuentas que se dieron de baja por cada motivo registrado.


Resultado: El reparto de motivos de baja no es uniforme:

motivo_churn	cuentas_churn	porcentaje
features	43	36.13
support	38	31.93
pricing	18	15.13
budget	9	7.56
unknown	7	5.88
competitor	4	3.36
	119	99.99

- El 36.13% de las cuentas que se dieron de baja alegan 'funcionalidades' como motivo de su cancelación.
- El 31,93% de las cuentas que se dieron de baja alegan problemas de soporte.

Estos dos motivos concentran 81 de las 119 cancelaciones, el 68,06 % del total, mientras que la mención a la competencia apenas alcanza cuatro casos. Los motivos de naturaleza económica se reparten entre el precio del servicio (15,13 %) y las restricciones presupuestarias del cliente (7,56 %), que conviene mantener separados: el primero señala una decisión sobre la propuesta de valor y admite respuesta comercial, mientras que el segundo responde a circunstancias ajenas a la empresa.


Distribución de motivos



Este **resultado** contrasta directamente con el obtenido en la **Fase 3** donde la misma consulta sobre el conjunto de datos original devolvía las seis categorías repartidas casi por igual y no permitía identificar ninguna causa dominante. Conviene precisar, no obstante, que *reason_code* recoge lo que el cliente declara al darse de baja.

Consulta 9. Coste monetario por motivo de cancelación.

En esta consulta se quiere saber qué representa en términos de pérdida de ARR cada motivo: lo determinante no es únicamente cuántas cuentas se pierden, sino de qué tramo de facturación proceden.



Resultado: El desglose del ARR perdido por motivo de baja altera un poco el ranking de la consulta anterior. En términos de pérdida de ingresos: los problemas de soporte, que ocupaban el segundo lugar en número de cancelaciones (31,93 %), pasan a encabezar la pérdida de ingresos con el 35,82 % del ARR fugado, mientras que la falta de funcionalidades desciende del 36,13 % al 31,96 %.

motivo_churn	cuentas_churn	cuentas_sin_valor	pct_cuentas	arr_perdido	pct_arr_perdido
support	38	1	31.93	2224776	35.82
features	43	1	36.13	1984812	31.96
pricing	18	1	15.14	1024068	16.49
budget	9	0	7.56	377184	6.07
unknown	7	0	5.88	338424	5.45
competitor	4	0	3.36	261312	4.21
	119	3	100	6210576	100

Pero conviene no sobredimensionar la diferencia, ya que se trata de 4 puntos. **La lectura sólida es que ambos motivos pesan de forma equivalente en términos económicos, con el soporte ligeramente por delante.**

Los motivos económicos de precio y presupuesto, mantienen posiciones equivalentes en ambas consultas, lo que sugiere que afectan a cuentas de tamaño representativo del conjunto. Tres cuentas dadas de baja carecen de valor monetario asignado y se distribuyen entre soporte, funcionalidades y precio, sin perjudicar en exceso a ningún motivo.

Consulta 10. Motivo de baja cruzado con el tamaño de la cuenta.

Sabemos por las anteriores consultas que el tamaño de la cuenta no es un indicador del churn, pero en esta consulta se pretende medir volumen de usuarios por familias de motivos: la **familia producto** reúne las carencias de funcionalidades y los problemas de soporte, mientras que la **familia comercial** agrupa motivos de precio, presupuesto y competencia.

familia_motivo	tramo_tamaño	cuentas	porcentaje
Comercial	Grandes	14	45.16
Comercial	Pequeñas	17	54.84
Producto	Grandes	40	49.38
Producto	Pequeñas	41	50.62
Sin especificar	Grandes	5	71.43
Sin especificar	Pequeñas	2	28.57
		119	

Resultado: agrupando los motivos en dos familias (producto y comercial) y partidas las bajas por la mediana de licencias, ambas familias se reparten de forma prácticamente equilibrada entre cuentas pequeñas y cuentas grandes. Se concluye que el motivo alegado al cancelar es independiente del número de licencias contratadas. El cruce entre el motivo declarado y el tamaño de la cuenta no revela ninguna relación

- **Comercial:** 45,16% cuentas grandes y 54,84% cuentas pequeñas se fueron por motivos económicos y/o de competencia.
- **Producto:** 49,38% cuentas grandes y 50,62% cuentas pequeñas se fueron por motivos de carencia de funcionalidades y/o falta de soporte.

Una precaución de lectura: cabe mencionar que esta consulta emplea el número de licencias registrado en la tabla de cuentas, magnitud que en este conjunto de datos no guarda correlación con el valor económico de la cuenta y que es una consecuencia de la desincronización entre tablas ya documentada en la Fase 3 y conservada en el entorno simulado del gemelo, por lo que **mide exclusivamente el tamaño en usuarios y no debe interpretarse como una medida del valor del cliente.**

Las siete cuentas cuyo motivo no fue especificado (*unknown*) se reportan por completitud, pero su número resulta insuficiente para cualquier lectura.


Consulta 11. Motivo cruzado con tiempo de vida.

Esta consulta introduce el factor tiempo, porque no es lo mismo perder a un cliente al mes de haberlo captado que perderlo después de dos años. Si los motivos alegados cambiaran según el momento de la marcha, cada etapa requeriría una respuesta distinta. Para comprobarlo se agruparon los seis motivos en las mismas dos familias que en la consulta anterior. Esta agrupación es estrictamente necesaria porque el cruce de seis motivos con varias franjas temporales dejaba celdas de una o dos cuentas, sin base suficiente para leer nada.

En la consulta, el tiempo de vida se dividió en tres franjas coincidentes con las empleadas en el análisis de permanencia:

- Hasta 90 días como **abandono temprano**.
- Entre 91 y 365 días como **abandono intermedio**.
- Y más de 365 días como **abandono tardío**.

Los porcentajes se calculan dentro de cada franja, de modo que puedan compararse las familias en cada momento de la vida del cliente.



Resultado: **Cuanto más tiempo permanece una cuenta, menos probable resulta que su marcha se atribuya al producto.**

En el gráfico podemos observar el porcentaje de las bajas de cada franja temporal. Existe una tendencia sostenida para los motivos de churn relacionados con producto: entre quienes abandonan en los tres primeros meses, el 75,86 % alega motivos de producto; la proporción baja al 69,84 % en la franja intermedia y al 55,56 % entre quienes superan el año. Los motivos comerciales recorren el camino inverso, del 20,69 % al 33,33 %.

Precaución de lectura: Conviene presentar este resultado como una tendencia y no como un hecho establecido.

Consulta 12. La prueba de coherencia.

Antes de dar por buenas las conclusiones del bloque conviene comprobar si lo declarado se corresponde con lo que los datos de uso y de soporte registran efectivamente. Las cuatro consultas anteriores se apoyan en *reason_code*, que es lo que el cliente dice al marcharse.

Esta consulta se divide en dos partes porque cada motivo predice una huella distinta: quien alega carencias de producto debería mostrar una adopción de funcionalidades menor, mientras que quien alega soporte debería presentar una experiencia de atención más deficiente.

Estas dos comparaciones son entre el resto de cuentas dadas de baja, y no frente a las activas: como todas se marcharon, la única diferencia relevante entre ellas es el motivo alegado.

- **Parte 12a:** Quien alega falta de funcionalidades, ¿usaba menos funcionalidades?

alega_features	cuentas	amplitud_media	frecuencia_media
0	76	9.53	220
1	43	8.42	173

Resultado: las 43 cuentas que alegan carencias de funcionalidades registran, en efecto, una adopción menor que el resto de bajas: 8,42 funcionalidades distintas frente a 9,53, con una intensidad de uso también inferior (173 frente a 220). El contraste con la Fase 3 resulta pertinente: en el conjunto original esta misma comprobación no mostraba diferencia alguna entre ambos grupos.

- **Parte 12b:** Quien alega problemas de soporte, ¿tuvo peor experiencia de soporte?

alega_soporte	cuentas	media_num_tickets	media_horas_resolucion	media_satisfaccion	pct_escalada
0	81	5.39	36.6	3.05	15.53
1	38	6.11	41.9	2.7	19.32

Resultado: el motivo declarado como soporte se corresponde con una experiencia de atención objetivamente peor en términos de tiempo de espera y satisfacción, pero no en volumen de incidencias.

Las 38 cuentas que alegan este motivo esperaron una media de 41,9 horas hasta la resolución de sus incidencias, frente a las 36,6 horas del resto de bajas, y puntuaron la atención recibida con un 2,70 sobre 5 frente al 3,05 de las demás.

Pregunta 4 — Anticipación: ¿qué señal temprana anticipa la baja?

Consulta 13. Señales de comportamiento antes de la baja frente a cuentas activas.

Esta consulta busca la señal que anticipa el abandono, y para ello compara el comportamiento de las cuentas dadas de baja con el comportamiento de las cuentas activas en los 90 días previos a su fecha de referencia. La elección de este momento es lo que distingue esta consulta de un análisis convencional: cada cuenta se observa desde su propia fecha de referencia (esta fecha de referencia es la fecha de baja para las cuentas que registran baja, o la fecha de fin de periodo del dataset para las cuentas que siguen activas), de modo que todas se examinan en una fase equivalente de su vida y ninguna métrica incorpora información posterior al hecho que se pretende anticipar.

¿Por qué 90 días? La ventana de 90 días responde a la convención habitual en negocios de suscripción, donde el trimestre coincide con los ciclos de facturación y de revisión comercial.

Se miden cuatro señales: los días transcurridos desde el último uso registrado, la intensidad media de cada evento de uso, el número de eventos y los errores técnicos por evento.

SEÑALES	Cuentas activas	Cuentas churn
Número de cuentas	381	119
Sin uso registrado en la ventana	1,8%	1,7%
(1) Días desde el último uso (recencia)	9,1	14,5
(2) Acciones por sesión de uso	10,35	4,59
(3) Eventos de uso en la ventana temporal	30	18,2
(4) Errores técnicos por sesión de uso	0,475	0,805

Resultado: las cuatro señales discriminan con claridad.

- **(1) Días desde el último uso:** las cuentas que se marchan registran de media 14,5 días frente a los 9,1 días de media de las cuentas activas.
- **(2) Intensidad de uso:** las cuentas que se marchan registran una media de 4,59 acciones por evento de uso registrado frente a las 10,35 de las activas, menos de la mitad.
- **(3) Frecuencia de uso:** las cuentas que se marchan registran una media de 18,2 eventos en el trimestre frente a 30 eventos de las activas. Esto indica que estas cuentas no solo hacen menos cada vez que entran, sino que, además, entran menos veces.

- **(4) Errores técnicos:** éstos casi se duplican para las cuentas que se marchan y se registran 0,805 errores por evento, frente a los 0,475 errores por evento de las cuentas activas.

El perfil que emerge aquí es coherente: una cuenta que se dirige hacia la baja reduce su actividad tanto en intensidad de uso como en frecuencia, y acumula más fricción técnica mientras lo hace. Ese deterioro resulta observable en el trimestre anterior a la cancelación (la ventana de 90 días). La única métrica que no distingue a los dos grupos es la ausencia total de uso en la ventana, que afecta a proporciones prácticamente idénticas (el 1,8 % de las activas y el 1,7 % de las bajas). De la interpretación de estos resultados **se concluye que el abandono no viene precedido de una desconexión completa sino de un debilitamiento progresivo, hallazgo relevante para el diseño del sistema de alerta temprana:** esperar al silencio absoluto supondría actuar demasiado tarde.

Consulta 14. Actividad y experiencia de soporte en los 90 días previos a la baja.

La consulta anterior nos explica que las cuentas que se van usan menos el producto y acumulan más errores. Se distingue de todas las anteriores porque su razón de existir es responder a la pregunta: **¿la experiencia de soporte también anticipa la baja?**

Un cliente frustrado con la atención recibida tiene una vía de escape que no aparece en los datos de uso. Puede seguir usando el producto con normalidad y aun así estar decidiendo marcharse por cómo lo trataron.

La ventana de 90 días aquí es obligatoria: si contara todos los tickets abiertos de la historia de cada cuenta, se sumarían tickets por antigüedad de la cuenta. La comparación quedaría contaminada por el tiempo de vida de la cuenta, igual que pasaba con las cohortes de la consulta 1.

Se compara por tanto la experiencia de soporte de las 119 cuentas dadas de baja con la de las 381 activas, en los noventa días previos a la fecha de referencia de cada una.

MÉTRICAS	Cuentas activas	Cuentas churn
Número de cuentas	381	119
Sin tickets registrados en ventana temporal	32%	13,4%
(1) Volumen de tickets abiertos	1,61	3,35
(2) Horas de espera para la resolución del ticket	31,2	38,8
(3) Minutos de espera para la primera respuesta	73,8	96
(4) Porcentaje de tickets escalados	7,18	16,37
(5) Satisfacción media	3,55	2,86

Resultado: las cinco métricas examinadas discriminan entre ambos grupos, y todas superan el margen de error correspondiente.

La primera diferencia aparece antes incluso de medir la calidad de la atención: solo el 13 % de las cuentas dadas de baja no había abierto ningún ticket en el trimestre previo, frente al 32 % de las activas. Es decir, la mayoría de quienes se marchan había necesitado ayuda poco antes de hacerlo.

- **(1) Volumen de tickets abiertos:** se duplica para las que se fueron: 3,35 tickets frente a 1,61.

La calidad del servicio recibido es sistemáticamente peor:

- **(2) Horas de espera para la resolución del ticket:** ésta se demora 38,9 horas frente a 31,2 horas.
- **(3) Minutos de espera para la primera respuesta:** la primera respuesta tarda 96 minutos frente a 73,8.
- **(4) Porcentaje de tickets escalados:** y la proporción de incidencias que requieren escalado pasa del 7,18 % al 16,37 %, más del doble.
- **(5) Satisfacción media:** la valoración del cliente recoge el resultado de todo lo anterior: 2,86 sobre 5 frente al 3,55 de las cuentas que permanecen.

El perfil que emerge es coherente y completa el dibujado por la consulta anterior: una cuenta que se dirige hacia la baja no solo usa menos el producto y acumula más errores técnicos, sino que además recurre más al soporte, espera más para ser atendida, ve escalar sus incidencias con mayor frecuencia y puntúa peor la atención recibida.

Ninguna de las dos vías es redundante respecto de la otra: la primera describe lo que la cuenta deja de hacer, la segunda lo que la empresa deja de resolver.

Para valorar si las diferencias observadas entre grupos son atribuibles al azar, se comparó cada diferencia de medias con su margen de error, calculado a partir de la desviación típica y el tamaño de cada grupo. Se consideran consistentes aquellas diferencias que superan el doble de dicho margen, criterio que corresponde aproximadamente al 95 % de confianza habitual.

El procedimiento es una aproximación a la comparación de medias entre muestras independientes y no sustituye a un contraste formal de hipótesis, que requeriría comprobar supuestos que este trabajo no aborda.


Consulta 15. El canal de captación como factor de riesgo estructural

A diferencia de las señales de comportamiento analizadas antes, el canal no anticipa un deterioro que se desarrolle con el tiempo; se conoce el día del alta y no cambia nunca. No es, por tanto, una alerta temprana, sino un factor de riesgo estructural disponible desde el primer día de la relación.

canal	cuentas	bajas	tasa_churn	dias_observacion	arr_perdido	pct_arr_perdido
ads	98	41	41.84	283	1948020	31.37
other	103	36	34.95	276	2098920	33.8
event	96	18	18.75	294	692832	11.16
partner	89	12	13.48	330	604032	9.73
organic	114	12	10.53	278	866772	13.96
	500	119	23.91	292.2	6210576	100.02

Resultado: el canal sí discrimina, y con holgura. Las cuentas captadas mediante publicidad de pago ('ads') cancelan al 41,84 %, frente al 10,53 % de las llegadas por búsqueda orgánica: cuatro veces más. Los tiempos de observación son comparables entre canales (de 276 a 330 días).

Tasa churn por canal de captación



El impacto económico acompaña al hallazgo: **publicidad de pago** y la categoría «**otros**» (contenido desconocido) reúnen el 40 % de la cartera y concentran el 65,2 % de toda la facturación perdida. A pesar de presentar la segunda tasa más alta, es la menos accionable.

Resulta llamativo, por contraste, que la búsqueda orgánica y los partners registren el mismo número de bajas (doce cada uno) pero con importes muy distintos: las pocas cuentas orgánicas que se marchan son las de mayor valor de todo el análisis.

Los datos no autorizan a concluir que la publicidad de pago sea una mala inversión: indican que capta clientes que permanecen menos tiempo, pero un canal cuyo coste de adquisición sea proporcionalmente bajo puede seguir siendo rentable aun con una rotación elevada. El conjunto de datos no recoge el coste de adquisición por canal, de modo que la conclusión defendible es que falta información para decidir, y no que proceda recortar la inversión.

▪ Resumen del análisis de churn y los hallazgos más importantes:

El diagnóstico permite responder a las cuatro preguntas de negocio planteadas, y sus respuestas apuntan todas en la misma dirección. **RavenStack ha perdido 119 de sus 500 cuentas en dos años, es decir, el 23,8 %, lo que equivale a 6,21 millones de dólares de facturación anual recurrente sobre un total de 27,96 millones.** El coste directo de esas bajas, en devoluciones abonadas, asciende a 1.934 dólares: tres mil veces menos que la facturación que esas cuentas ya no generarán.

❶ Ninguna característica propia del cliente explica el abandono.

El abandono afecta por igual a toda la cartera de clientes y no distingue tamaño, plan de suscripción o sector. Lo confirman todas las variables que describen quien es el cliente. La única excepción es el canal por el que entró el cliente. **Las cuentas captadas por publicidad de pago cancelan cuatro veces más que las que llegaron por búsqueda orgánica** (41,8 % frente a 10,5 %). Es el único rasgo identificable en el momento de la venta que anticipa el resultado.

❷ Lo que sí explica el abandono es la experiencia del usuario.

Dos de cada tres cancelaciones se atribuyen a producto o a soporte, y ninguna a un fallo puntual: el deterioro es gradual y visible con antelación. En los 90 días previos a la baja las cuentas que cancelan **estaban usando el producto la mitad de lo habitual, acumulando el doble de errores técnicos y esperando más por un soporte que resolvía peor sus incidencias.**

La conclusión operativa es que estas bajas eran detectables antes de producirse, y que hoy por hoy el negocio no dispone de ningún mecanismo que las detecte.

❸ El riesgo es uniforme, pero el daño económico no.

La facturación está muy concentrada: el 10 % de las cuentas aporta el 31,7 % de los ingresos, y el 30 % superior concentra el 64,3 %. **Como la probabilidad de cancelar es uniforme, el impacto económico recae de forma desproporcionada sobre las cuentas grandes.**

🔧 La conclusión operativa es doble:

Primero, que estas bajas eran detectables antes de producirse con información que la empresa ya poseía. Segundo, que cualquier esfuerzo de retención que trate a todas las cuentas por igual está mal dirigido por construcción, porque el riesgo es uniforme pero el valor expuesto no lo es.

▪ Del diagnóstico a la decisión: SOLUCIÓN PROPUESTA.

De ahí el objeto de la fase siguiente: un **sistema de alerta temprana** que puntúe la cartera viva combinando las seis señales que han demostrado capacidad discriminante:

1. Intensidad de uso por sesión.
2. Frecuencia de uso en el trimestre.
3. Errores técnicos por sesión.
4. Volumen de incidencias abiertas.
5. Tasa de tickets escalados.
6. Satisfacción.

Se deja fuera los tiempos de resolución y de primera respuesta a propósito porque miden lo mismo que la satisfacción y el escalado.

Las cuentas resultantes **serán priorizadas por facturación expuesta**, de modo que la **atención se dirija primero a donde la pérdida sería mayor**.

El sistema incorpora además una **priorización/recomendación de funcionalidades para las cuentas señaladas**, construida sobre la brecha de adopción entre cuentas sanas y cuentas en riesgo.

Fase 6 · Sistema de alerta temprana y recomendador de funcionalidades.

Objeto y restricciones de diseño

El diagnóstico estableció tres conclusiones que determinan el diseño de esta fase.

1. **El abandono** no depende de quién es el cliente sino de lo que le ocurre. (La única excepción es el **canal** por el que entró el cliente.)
2. **El deterioro** se da de forma gradual y observable en el trimestre anterior a la baja.
3. **El daño económico** se concentra en una minoría de cuentas.

Sobre estas conclusiones se construye un sistema que puntúa la cartera viva, la ordena por riesgo y valor expuesto, y propone a cada cuenta señalada qué funcionalidades incorporar.

Dos restricciones de diseño se derivan del propio diagnóstico. El motivo de baja, pese a ser informativo en el análisis, no puede alimentar el sistema: solo se conoce cuando el cliente ya se ha marchado.

Y las métricas deben calcularse con un corte temporal estricto, empleando únicamente información anterior a la fecha de evaluación, para evitar la fuga de información que invalidó el conjunto de datos original.

Se optó por una tarjeta de puntos y no por un modelo estadístico entrenado. La decisión responde al caso de uso: el sistema no ejecuta ninguna acción automática, sino que produce una lista que un equipo humano debe atender, y nadie contacta sin un cliente sin saber por qué aparece señalado.

Código de las vistas creadas en esta fase: [03_documento_vistas.sql](#).

6.1. Las señales

Se emplean las 6 señales que superaron el contraste estadístico en la fase anterior, agrupadas en dos familias:

1. **Familia Producto:** intensidad de uso + número de sesiones + errores técnicos.
2. **Familia Soporte:** volumen de incidencias + satisfacción + tasa de escalado.

Se valoró incorporar el canal de captación como séptima señal, dado que la Fase 5 lo identificó como la única variable estructural con capacidad discriminante. Pero finalmente se descartó por dos motivos:

- Se trata de un atributo estático y el objetivo del sistema de alerta es detectar el deterioro en el tiempo: **una cuenta captada por publicidad arrastraría una penalización permanente con independencia de su estado real de deterioro.**
- Al incorporarlo a la prueba de validación, **el lift mejoraba con fecha de corte en junio y empeoraba con fecha de corte en marzo**, sin ganancia consistente.

El canal se mantiene, por tanto, como factor de riesgo estructural documentado en el diagnóstico, cuya acción correspondiente se sitúa en la política de captación y no en la retención.

El tiempo medio de resolución se incorpora como una columna de contexto sin puntuación, por medir la misma dimensión que la satisfacción y no aportar información independiente; su utilidad es explicativa, pues permite entender por qué una cuenta con una sola incidencia puede haberla valorado mal.

Los valores nulos reciben un tratamiento expresamente asimétrico, que se justifican a continuación:

- **La ausencia de uso se convierte en cero**, porque una cuenta que no utiliza el producto se encuentra en la peor situación posible.
- **La ausencia de incidencias se conserva como nulo y no puntúa**, porque no haber necesitado ayuda no es un indicio negativo, sino lo contrario.

Estas decisiones afectan a 122 de las 381 cuentas vivas y evitan penalizar a casi un tercio de la cartera por un motivo favorable.

6.2. La puntuación

Cada señal aporta entre cero y dos puntos, con un máximo de doce. Las señales se puntúan de la siguiente manera:

- 1- **Familia Producto:** Se puntúan por terciles porque no tienen una referencia absoluta, ya que no existe un número de sesiones que se considere 'poco' con independencia del resto de la cartera.
- 2- **Familia Soporte:** Se puntúan mediante umbrales fijos porque aquí sí existe una referencia absoluta: una satisfacción inferior a 3 (sobre 5) es mala por propia definición.

La familia de producto resulta con mayor efectivo que la de soporte. El resultado es coherente con el diagnóstico, donde la intensidad de uso fue la señal más discriminante de todas, y con el hecho de que el recomendador se construye sobre funcionalidades.

6.3. La matriz de priorización

La puntuación se cruza con el decil de facturación de cada cuenta, generando una matriz de nueve casillas que se traducen en cuatro acciones. Se combinan riesgo con valor de con 4 índices diferentes y se obtiene 4 grupos y acciones diferentes para cada grupo. Esto es así porque una cuenta pequeña en mal estado exige una respuesta distinta de una cuenta grande en estado más estable, pero con señales de deterioro.

<i>Acción</i>	<i>Cuentas</i>	<i>Valor expuesto</i>
1. Intervención directa	13	1.683.108 USD
2. Contacto proactivo	54	5.081.292 USD
3. Campaña publicitaria	62	2.223.156 USD
4. Sin acción	240	12.757.668 USD

El diseño resuelve la tensión planteada al cierre del diagnóstico. Las 13 cuentas de intervención directa constituyen una lista que un equipo reducido puede trabajar en una semana. Las 62 de campaña automatizada recogen el problema de volumen de las cuentas pequeñas (que sumadas exponen más facturación que el primer grupo) sin exigir una atención individualizada.

12 cuentas vivas han quedado fuera de la matriz por carecer de facturación asignada en la fecha de referencia, circunstancia ya documentada en el análisis de ingresos.

Los umbrales de riesgo (en el código 8 y 5), constituyen un parámetro operativo y no se trata de ningún hallazgo. Pero desplazarlos ampliaría y reduciría esta clasificación y puede elevar la cartera de vigilancia del 41% (como ahora) al 55%, y eso es un umbral a partir del cual un sistema de alertas pierde credibilidad operativa.

6.4. La validación

Un sistema construido a partir de cuentas que ya se marcharon corre el riesgo de describir el pasado en lugar de anticipar el futuro. Para descartarlo se realizó una prueba retrospectiva: situándose en el 30 de junio de 2024, se puntuó la cartera viva en esa fecha empleando únicamente información anterior a ella, y se observó qué cuentas se dieron de baja en los 180 días siguientes.

Nivel de riesgo	Cuentas	Bajas posteriores	Tasa	Lift
Alto	18	7	38,89%	2,74
Medio	87	17	19,54%	1,38
Bajo	142	11	7,75%	0,55

Sobre una población de 247 cuentas con una tasa base del 14,17%, el grupo señalado como riesgo alto abandonó con un ritmo 5 veces superior al del grupo de riesgo bajo. **El lift de 2,74 indica que el sistema concentra casi tres veces más bajas que las que se obtendrían seleccionando cuentas al azar.** La progresión entre niveles es continua y el orden se mantiene al repetir el ejercicio con fecha de corte en marzo.

Conviene no sobredimensionar la cifra exacta: dieciocho cuentas son pocas, y el desplazamiento de dos de ellas mueve el porcentaje varios puntos. El resultado es sólido en dirección y ordenación, no en magnitud.

6.5. El recomendador de funcionalidades

El sistema se completa proponiendo a cada cuenta señalada las funcionalidades que las cuentas sanas adoptan y ella no. **El criterio es la brecha de adopción y no la popularidad:** recomendar lo que utiliza la mayoría no aporta información, puesto que la cuenta en riesgo probablemente ya lo utilice por popularidad.

El cálculo obligó a introducir una corrección. Las cuarenta funcionalidades del producto presentan brecha favorable a las cuentas sanas, sin una sola excepción. Esto hizo sospechar de ser un artefacto del dataset. La comprobación lo confirmó: una cuenta sana utiliza 16,58 funcionalidades distintas de media frente a las 10,65 de una cuenta en riesgo, de modo que cualquier funcionalidad examinada aparece más adoptada entre las cuentas sanas por el simple hecho de que exploran más y tienen más amplitud de uso.

Si esa diferencia de amplitud fuese la única causa, cada funcionalidad mostraría una brecha de 14,83 puntos (la diferencia de amplitud media, 16,58 frente a 10,65 funcionalidades, repartida entre las cuarenta funcionalidades disponibles), umbral que solo 15 de ellas superan. Esas 15 constituyen el conjunto de candidatas del recomendador y son las que pasan el filtro con el HAVING en la CTE creada. En la práctica se proponen 9, porque cada cuenta recibe únicamente sus 3 mejores candidatas y las de menor brecha solo emergerían para cuentas que ya adoptasen todas las anteriores. Esta diferencia se marca en la creación de una función de ventana (ROW_NUMBER()) que particiona por cuenta y ordena por brecha de adopción. Al final se añade WHERE orden ≤ 3 y nos quedamos con las tres primeras funcionalidades que aparecen para cada cuenta.

El resultado **son 387 propuestas repartidas entre 129 cuentas, con un máximo de tres funcionalidades por cuenta, procedente de 9 funcionalidades distintas.** Una cuenta queda sin propuesta por utilizar ya todas las *features* candidatas.

Funcionalidad	Brecha	Veces propuesta	
<i>feature_9</i>	27,73	107	80%
<i>feature_13</i>	23,54	102	
<i>feature_33</i>	22,46	101	
<i>feature_38</i>	20,06	47	20%
<i>feature_11</i>	19,88	22	
<i>feature_24</i>	19,58	4	
<i>feature_34</i>	19,38	1	
<i>feature_29</i>	17,89	2	
<i>feature_27</i>	17,39	1	

La personalización existe, pero es limitada y hay que declararlo: cada cuenta recibe una combinación distinta en función de lo que ya adopta, aunque 3 funcionalidades (*feature_9*, *feature_13* y *feature_33*) **aparecen en cerca del 80% de las propuestas.**

Esto indica que la carencia de estas tres es común a la mayoría de la cartera en riesgo, y sugiere que **la recomendación debe entenderse tanto como una acción individual como una prioridad para el conjunto.**

Dos cautelas antes de cerrar el apartado:

1. La relación observada es de correlación y no de causalidad: es posible que las cuentas satisfechas exploren más precisamente por estarlo, y establecer la dirección exigiría un experimento controlado sobre un grupo de prueba.
2. Las funcionalidades del conjunto de datos no tienen descripción, por lo que no se puede valorar si las candidatas a recomendación guardan coherencia funcional entre sí. Es una comprobación que en un entorno real le correspondería al equipo de producto.

Fase 7 · Visualización en Power BI

7.1. Objeto de la fase

Las fases anteriores dejan el análisis resuelto pero encerrado en scripts SQL que solo puede leer quien sepa consultarlos. Esta fase traduce el trabajo a un formato que un comité de dirección y un equipo de retención puedan utilizar sin conocimientos técnicos.

El criterio que ordena el diseño es que cada página responda a una sola pregunta, y que las cuatro preguntas se encadenen siguiendo el mismo hilo que la memoria: cuánto se pierde, por qué, a quién atender y qué hacer con cada cuenta.

Las dos primeras páginas se leen y se cierran. Las dos últimas son herramientas de trabajo destinadas a consultarse de forma recurrente. Esa diferencia de uso se refleja en el diseño: las primeras priorizan la narración y las segundas la operatividad, con filtros y detalle por cuenta.

<i>Página</i>	<i>Pregunta que responde</i>	<i>Quién la usa</i>
1. <i>Situación general</i>	¿Cuánto estamos perdiendo?	Dirección
2. <i>Diagnóstico</i>	¿Por qué se van?	Dirección y Producto
3. <i>Cartera en riesgo</i>	¿A quién hay que atender?	Customer Success y Dirección
4. <i>Plan de acción</i>	¿Qué le decimos a cada uno?	Customer Success

7.2. Origen de los datos y modelo

El panel consume directamente de las vistas creadas en MySQL, en modo importación. La decisión de importar y no consultar en vivo responde a que el fichero debe poder abrirse sin la base de datos disponible.

Código de las vistas creadas en esta fase: [03_documento_vistas.sql](#).

Se creó una vista específica para el panel, **bi_hechos_cuenta**, que reúne en una sola fila por cuenta el estado de baja, la facturación, las señales de comportamiento, la puntuación de riesgo y la acción asignada. Combinar las cinco vistas del análisis en origen evita replicar esa lógica dentro de Power BI, donde resultaría menos legible y no podría reutilizarse.

El modelo adopta una estructura en estrella con **dim_cuentas** como tabla central, que conserva los atributos estables del cliente: sector, país, canal de captación, plan y licencias. Y dos tablas relacionadas por *account_id*: **hechos_cuentas**, con lo que le ocurre a cada cuenta, y **recomendador**, con las propuestas de funcionalidades. Dos tablas permanecen sin relación por venir ya agregadas: la serie mensual de altas y bajas, y el comparativo de señales. La **serie de altas y bajas** se agregó en SQL en lugar de resolverse con una tabla de calendario. El motivo es que altas y bajas corresponden a dos fechas distintas de la misma cuenta, y un calendario solo puede relacionarse con una a la vez, lo que habría exigido relaciones inactivas y expresiones DAX innecesarias para un gráfico de veinticuatro puntos.

7.3. Portada y advertencia sobre el origen de los datos

Una página inicial de navegación reúne los accesos a las cuatro secciones acompañados de una descripción de su contenido y de su destinatario.

Esa portada recoge también, de forma visible, la advertencia de que RavenStack es una empresa ficticia y que los datos son sintéticos. La advertencia figura igualmente en el informe ejecutivo y en el resumen de esta memoria: un panel puede consultarse de forma aislada, y quien lo abra debe conocer la naturaleza de los datos en la primera pantalla y no al final de un documento que quizá no lea. Además, todas las páginas tienen un **botón de navegación** a la parte inferior derecha que permite dirigirse a la página siguiente, a excepción de la última página que devuelve al índice: 

Enlace al cuadro de mando en Power BI Service:




[Dashboard Ravenstack](#)

7.4. Página 1 · Situación del negocio

Pregunta: ¿Cuánto estamos perdiendo?

Destinatario: Comité de Dirección.



Presenta la magnitud del abandono y su traducción económica mediante seis indicadores: cuentas totales, activas y perdidas, facturación total, facturación perdida y porcentaje de ingresos perdido.

Contiene un gráfico de líneas con la evolución mensual de altas y bajas, un gráfico circular con el porcentaje de cuentas perdidas respecto al total de cuentas del negocio y un gráfico de barras a modo comparación de la facturación viva frente a la perdida.


El gráfico de líneas se configuró con eje continuo y escala única. La escala compartida es deliberada: con dos ejes independientes, las series se cruzan visualmente sin que se crucen sus valores, sugiriendo que las bajas superan a las altas en algún momento, cosa que no ocurre.

Se le añade también un segmentador de datos para poder ver las altas y las bajas a través de los trimestres y años.

7.5. Página 2 · Diagnóstico del abandono

Pregunta: ¿Por qué se van?

Destinatario: Dirección y Equipo de Producto.



Es la página que sostiene el argumento del proyecto, y su estructura es poco convencional: **enseña primero lo que no explica el abandono**. El bloque izquierdo recoge las tasas de cancelación por sector, tamaño de cuenta y plan contratado, todas en gris claro y todas orbitando el 23,8 % general. La ausencia de color es intencionada: la planitud es el mensaje.

El bloque derecho contrapone las seis señales de comportamiento que sí discriminan. El primer gráfico de columnas compara el deterioro de las cuentas perdidas frente a las activas. Las cifras del comparativo de señales se introdujeron manualmente por proceder de consultas cuyo resultado no está disponible en ninguna vista: las métricas de riesgo se calculan únicamente sobre la cartera viva, de modo que no permiten la comparación con las cuentas perdidas. Los valores corresponden a las consultas 13 y 15 de la Fase 5.

El segundo gráfico de columnas recoge los motivos declarados y distingue las señales de producto de las de soporte, puesto que las seis indican deterioro y colorearlas por dirección sugeriría erróneamente que tres son favorables. Recoge el porcentaje de bajas y el porcentaje de ingresos perdidos por motivo.

El gráfico de anillos el canal de captación, única variable estructural con capacidad predictiva.

7.6. Página 3 · Cartera viva en riesgo

Pregunta: ¿A quién hay que atender?
Destinatario: Equipo de Customer Success y Dirección.



Traslada al panel la matriz de priorización de la Fase 6.

Tres tarjetas arriba a la izquierda resumen las acciones con su número de cuentas y facturación expuesta, y una matriz en la parte inferior izquierda cruza el nivel de riesgo con el nivel de valor mostrando ambas magnitudes en cada casilla.

Se incorporó un gráfico que descompone la puntuación media de cada acción entre sus dos familias, producto y soporte. Sin él, quien fuera a contactar con una cuenta conocería su nivel de riesgo pero no su naturaleza, y esa distinción es la que determina si la conversación corresponde a producto o a soporte.


Una tabla a la parte inferior derecha recoge las 13 cuentas señaladas alto riesgo de abandono y alto valor expuesto, con su identificador y la facturación de cada una de ellas. Se trata de las cuentas que tienen alta prioridad de acción.

Una tarjeta de texto arriba de la página recoge la validación: el resultado de la prueba retrospectiva expresado sin terminología técnica: el sistema acierta 2,7 veces más que una selección aleatoria. Su función es responder por anticipado a la pregunta sobre en qué se fundamenta la lista, que un panel consultado fuera del contexto de la memoria no puede responder por sí solo.

7.7. Página 4 · Plan de acción

Pregunta: ¿Qué hacemos con cada cuenta?

Destinatario: Equipo de Customer Success.



Es la única página concebida como herramienta operativa.

Contiene 4 segmentadores: identificador de cuenta, acción necesaria, riesgo de abandono y valor de la cuenta. Todos ellos filtran una tabla ordenada por facturación descendente que muestra, para cada cuenta, su acción asignada, su facturación, sus puntos de riesgo desglosados por familia y las funcionalidades propuestas.

Las columnas de puntos incorporan barras de datos, de modo que el perfil del problema se percibe sin leer cifras. Al seleccionar una cuenta en concreto, en el panel superior se pueden ver sus métricas concretas: uso por sesión, sesiones en el trimestre, incidencias, satisfacción y horas de resolución.

7.8. Medidas DAX

Medida	Código	Justificación
Cuentas totales =	<code>COUNTROWS('hechos_cuentas')</code>	Base sobre la que se construyen las demás medidas de recuento
Cuentas activas =	<code>CALCULATE([Cuentas], 'hechos_cuentas'[estado_cuenta] = "Activa")</code>	Reutiliza la medida base añadiendo un filtro, en lugar de repetir el recuento
Cuentas perdidas =	<code>CALCULATE([Cuentas], 'hechos_cuentas'[estado_cuenta] = "Perdida")</code>	Lo mismo que para 'Cuentas activas'.

Tasa de abandono=	<code>DIVIDE([Cuentas perdidas],[Cuentas])</code>	Se emplea DIVIDE y no el operador de división para evitar error si el denominador fuese cero.
Facturación total=	<code>SUM('hechos_cuentas'[facturacion])</code>	Base de las medidas económicas.
Facturación viva=	<code>CALCULATE([Facturación], 'hechos_cuentas'[estado_cuenta] = "Activa")</code>	Facturación de las cuentas que permanecen.
Facturación perdida=	<code>CALCULATE([Facturación], 'hechos_cuentas'[estado_cuenta] = "Perdida")</code>	Facturación de las cuentas dadas de baja.
% de ingresos perdido=	<code>DIVIDE([Facturación perdida],[Facturación])</code>	Traduce la pérdida a proporción, comparable con la tasa de abandono.
% de bajas por motivo=	<code>DIVIDE([Cuentas perdidas], CALCULATE([Cuentas perdidas], ALL('hechos_cuentas'[motivo_baja])))</code>	ALL elimina el filtro de motivo del denominador; sin él, cada categoría se dividiría entre sí misma y devolvería 100 %
% de pérdida por motivo=	<code>DIVIDE([Facturación perdida], CALCULATE([Facturación perdida], REMOVEFILTERS('hechos_cuentas'[motivo_baja])))</code>	Ídem, aplicado a la facturación
Cuentas en riesgo=	<code>CALCULATE([Cuentas], 'hechos_cuentas'[accion] IN {"1. Intervencion directa", "2. Contacto proactivo", "3. Campaña automatizada"})</code>	Se enumeran las acciones en lugar de excluir «Sin acción», para que las cuentas ajenas a la matriz —sin acción asignada— no se incorporen involuntariamente
Facturación riesgo=	<code>CALCULATE([Facturación], 'hechos_cuentas'[accion] IN {"1. Intervencion directa", "2. Contacto proactivo", "3. Campaña automatizada"})</code>	Ídem, aplicado a la facturación
Puntos Producto=	<code>AVERAGE('hechos_cuentas'[puntos_producto])</code>	Permite comparar el peso de cada familia de señales entre acciones
Puntos Soporte=	<code>AVERAGE('hechos_cuentas'[puntos_soporte])</code>	Lo mismo que Puntos Producto.
Funcionalidades a proponer	<code>CONCATENATEX('recomendador', 'recomendador'[feature_name], ", ", 'recomendador'[orden], ASC)</code>	La tabla contiene tres filas por cuenta; CONCATENATEX las reúne en una sola celda respetando el orden de brecha
Uso por sesión=	<code>AVERAGE('hechos_cuentas'[columna])</code>	Se emplea AVERAGE y no SUM para que devuelvan el valor individual al seleccionar una cuenta y la media del conjunto sin selección
Sesiones=		
Incidencias=		
Satisfacción=		
Horas de resolución=		

Se crearon además **dos columnas calculadas**: el tramo de tamaño de cuenta, con los mismos cortes por cuartiles empleados en el diagnóstico, y las columnas de ordenación de riesgo y valor.

Estas últimas se resolvieron en la vista SQL y no en DAX. Definirlas como columnas calculadas a partir de las etiquetas que después debían ordenar generaba una dependencia circular que Power BI rechaza: la etiqueta necesitaba el orden y el orden se derivaba de la etiqueta. Trasladar el cálculo al origen rompe esa circularidad, puesto que ambas columnas llegan ya resueltas desde la base de datos.

Power BI consume de la base de datos y no de ficheros sueltos. El flujo del proyecto queda así cerrado de extremo a extremo:

Kaggle → Python → MySQL → Power BI.

7.9. Modelo de datos

El modelo adopta una estructura en estrella con **dim_cuentas** como tabla central, que reúne los atributos estables del cliente que no cambian: el país, sector, plan, canal de captación, licencias y fecha de alta. Desde esta tabla parten dos relaciones por *account_id* con dirección de filtro simple: una de uno a uno con **hechos_cuentas**, que recoge lo que le ocurre a cada cuenta (estado, facturación, señales de comportamiento, puntuación de riesgo y acción asignada), y otra de uno a varios con **recomendador**, que contiene tres filas por cuenta correspondientes a las funcionalidades propuestas. Las tablas **altas_y_bajas** y **señales_comparativa** permanecen deliberadamente sin relación por llegar ya agregadas desde el origen: alimentan a un único visual cada una y vincularlas no aportaría capacidad de filtrado, solo complejidad al modelo.

Esta separación entre lo que la cuenta *es* y lo que le *pasa* es la que permite filtrar cualquier página por sector, país o canal sin duplicar esos atributos en varias tablas.




Figura 2. Modelo relacional del dataset RavenStack gemelo en Power BI.

7. LIMITACIONES DEL TRABAJO

Sobre el conjunto original. La auditoría de la Fase 3 (*) no agotó la lista de consultas previstas. La decisión de cerrarla se justifica en la naturaleza de la sexta evidencia: **una vez establecido que la relación temporal entre tablas era incoherente**, las consultas restantes no podían modificar el veredicto.

Sobre el origen de los datos modificado (dataset gemelo). Los hallazgos de las fases 5 y 6 proceden de un conjunto de datos **generado para este proyecto**, no de la operación de una empresa real. Describen el comportamiento de un entorno construido y no deben leerse como conclusiones sobre clientes reales. Lo que el trabajo demuestra es que el procedimiento analítico funciona; no qué causa el abandono en un negocio concreto.

Sobre el tamaño de la muestra. El conjunto contiene 500 cuentas y 119 bajas. Es suficiente para las comparaciones principales, pero cualquier segmentación adicional agota rápidamente la base: al cruzar el motivo de baja con el tamaño o el tiempo de vida hubo que agrupar las seis categorías en dos familias para que las celdas tuvieran cuentas suficientes. La validación del sistema de alerta se apoya en 18 cuentas de riesgo alto, de modo que su resultado es sólido en dirección, pero no en la cifra exacta.

Sobre lo que no pudo medirse. El conjunto no recoge el coste de adquisición por canal, sin el cual no puede valorarse si la publicidad de pago sigue siendo rentable pese a captar clientes que duren menos. Tampoco incluye el coste operativo de atender una cuenta en riesgo, lo que impide calcular el retorno de las acciones propuestas. Y las funcionalidades del producto carecen de denominación descriptiva, de manera que no es posible juzgar si las señaladas por el **recomendador** guardan coherencia entre sí.

Sobre las decisiones metodológicas. Los contrastes entre grupos se realizaron comparando la diferencia de medias con su margen de error (*), procedimiento que aproxima, pero no sustituye a un contraste formal de hipótesis. El análisis por tramos de permanencia arrastra un sesgo de exposición que no se corrigió: las cuentas incorporadas al final del periodo no han tenido tiempo de alcanzar los tramos superiores, y separar ese efecto exigiría análisis de supervivencia.

Por último, el **recomendador** identifica una correlación y no una relación causal: es posible que las cuentas satisfechas exploren más funcionalidades precisamente por estarlo, y establecer la dirección requeriría un experimento controlado.

(*) **Nota:** Los cálculos estadísticos de desviación estándar y el margen de error, así como los scripts iniciales convertidos en una auditoría de datos son documentos que no se entregan en este proyecto por no sobrecargar de información al evaluador, ya que solamente añade complejidad a la comprensión del flujo de trabajo. Asimismo, los scripts existen, están guardados y bien informados y documentados, por lo que pueden pedirse para su revisión cuando sea necesario.

8. CONCLUSIONES

Este proyecto no terminó donde empezó, y esa es su principal conclusión.

El diagnóstico sobre el dataset original resultó imposible, y demostrarlo fue el primer resultado. El análisis inicial de RavenStack no encontró ninguna variable capaz de separar a los clientes que se marchan de los que permanecen. Ante esa situación caben dos salidas: forzar una explicación sobre resultados que no la sostienen, o averiguar por qué. La segunda condujo a un hallazgo que ninguna consulta de negocio habría revelado: el 83,8 % de las cuentas dadas de baja registraba uso del producto con posterioridad a su cancelación. La relación temporal entre tablas está rota, y con ella cualquier posibilidad de anticipar el abandono. La fase se cerró con un veredicto sobre la calidad del dato en lugar de con un diagnóstico ficticio.

Un resultado negativo no vale de nada si no puede distinguirse de un fallo propio. Concluir que no hay señal deja abierta la duda de si el problema es el dato o el analista. Resolverla exigió construir un conjunto de datos con verdad conocida: conservar el mismo esquema, mismos volúmenes, mismos defectos, pero con una señal inyectada de magnitud determinada. Se ejecutó sobre él el mismo procedimiento y el método detectó la señal. El silencio en RavenStack quedó así establecido como propiedad del dato y no como limitación del análisis.

El diagnóstico posterior invirtió la hipótesis de partida. Ninguna característica del cliente explica el abandono: ni el plan contratado, ni el sector, ni el número de licencias, ni la facturación. Lo que lo explica es la experiencia. Las cuentas que se marchan usan el producto menos de la mitad, acumulan casi el doble de errores técnicos y reciben peor atención de soporte. Y ese deterioro es gradual: la desconexión total es igual de infrecuente entre las cuentas que se van y las que se quedan, de modo que esperar al silencio para intervenir supone llegar tarde en casi todos los casos.

El daño, en cambio, no se reparte por igual. La probabilidad de cancelar es uniforme en toda la cartera, pero el 30 % de cuentas de mayor facturación concentra el 64 % de los ingresos. Once bajas del decil superior cuestan casi cuatro veces más que cuarenta y dos del inferior. Cualquier esfuerzo de retención que trate a todas las cuentas por igual está mal dirigido por construcción.

Sobre esas conclusiones se construyó un sistema utilizable. Una tarjeta de puntos que combina seis señales observables, las cruza con el valor expuesto de cada cuenta y devuelve trece cuentas para atención directa sobre una cartera de 381. Se eligió deliberadamente frente a un modelo estadístico entrenado: el sistema no ejecuta ninguna acción automática, sino que produce una lista que un equipo humano debe atender, y una recomendación que nadie entiende es una recomendación que nadie usa.

La prueba retrospectiva confirmó que funciona: las cuentas señaladas como riesgo alto abandonaron cinco veces más que las de riesgo bajo.

Lo que este trabajo demuestra, en última instancia, no es qué causa el abandono en RavenStack. Es que un procedimiento analítico puede validarse a sí mismo, que un resultado negativo bien establecido tiene tanto valor como uno positivo, y que reconocer los límites de los datos disponibles es preferible a construir conclusiones que no los resisten.

Nota sobre el uso de herramientas de inteligencia artificial

El desarrollo de este proyecto contó con el apoyo de **Claude (Anthropic)**  como herramienta de asistencia técnica. Su participación se concretó en cuatro ámbitos:

1. La **generación del conjunto de datos gemelo** y del script generador descrito en la Fase.
2. La revisión y corrección del código SQL, incluida la detección de errores en consultas de elaboración propia.
3. La orientación metodológica sobre contraste de diferencias, diseño del sistema de puntuación y estructura del panel.
4. El apoyo en la redacción de esta memoria.

Las decisiones analíticas —qué consultas realizar, cómo interpretar los resultados, qué umbrales aplicar, qué conclusiones se sostienen y cuáles no— corresponden a la autora, así como la escritura de la mayor parte de las consultas SQL y la totalidad del desarrollo en Power BI. El criterio de trabajo adoptado fue no incorporar código que la autora no pudiera explicar y defender, lo que llevó en varias ocasiones a sustituir soluciones propuestas por otras más sencillas.

9. BIBLIOGRAFÍA

La atribución del dataset

River @ Rivalytics. RavenStack: Synthetic SaaS Dataset (Multi-Table).

Kaggle. Licencia MIT-like. Datos totalmente sintéticos, sin información personal.

<https://www.kaggle.com/datasets/rivalytics/saas-subscription-and-churn-analytics-dataset>

Herramientas y librerías

pandas · NumPy · SQLAlchemy · PyMySQL · python-dotenv · kagglehub · MySQL 8.0
· MySQL Workbench · Microsoft Power BI Desktop

Documentación de Power BI

Microsoft. Referencia de DAX. <https://learn.microsoft.com/es-es/dax/>

El uso de la IA

Anthropic. Claude [modelo de lenguaje]. Asistencia técnica y de redacción. Véase la nota sobre uso de IA al final del apartado CONCLUSIONES.

Referencias metodológicas

- Churn de logos frente a churn de ingresos y por qué son magnitudes distintas:

[Métricas y Análisis de Churn: Medir y Comprender la Pérdida de Clientes](#)

[Que es churn rate. Marketing digital. IEBS Business School](#)

- El concepto de lift en evaluación de modelos:

[¿Qué es Lift en la ciencia de datos?](#)

Anthropic. Claude [modelo de lenguaje]. Asistencia técnica.

Documentación técnica:



Bootcamp Unicorn Academy - Python, SQL y Power BI

INTEGER TYPES:

<https://dev.mysql.com/doc/refman/8.4/en/integer-types.html>

CHAR vs VARCHAR

<https://dev.mysql.com/doc/refman/9.7/en/char.html>

ENUM

<https://dev.mysql.com/doc/refman/9.7/en/enum.html>

DATE, DATETIME or TIMESTAMP

<https://dev.mysql.com/doc/refman/9.7/en/datetime.html>

SQL : [COUNT OVER PARTITION BY: Una Explicación con 3 Ejemplos Prácticos](#)

Cursos SQL de soporte:



Curso Datacamp: [SQL Intermedio](#)



Youtube: [Funciones de Ventana](#)



Curso Learn SQL: [Curso Funciones de Ventana](#)



Curso Udemy: [SQL TOTAL - Domina Bases de Datos de 0 a Avanzado en 12](#)

[Días](#)

